

## 研究工作报告

# 智能应急通信与定位增强方法研究

---

刘振宇

---

2023年5月

# 智能应急通信与定位增强方法研究

RESEARCH ON INTELLIGENT EMERGENCY COMMUNICATION AND  
LOCALIZATION ENHANCEMENT METHODS

作者 刘振宇

2023 年 5 月

## 内 容 摘 要

在自然灾害处置、事故灾难救援等应急场景中，往往存在环境复杂、公网缺损、卫星拒止的情况，导致了现场人员通信不畅、定位不准等问题。建立新型智能应急通信网络，支持应急现场网络的快速补盲与弹性恢复，提供通信传输和定位服务保障，对提高减灾救灾能力至关重要。然而，应急现场救援存在灾情种类多、地理环境复杂的特点，对智能应急通信网络提出了差异化的需求。在人口密集区域中，需要及时恢复与增强移动通信公网，帮助民众在紧急情况下及时上报信息和求助等；在山地林区等恶劣环境中，需要针对灾害发生后待救援区域的网络覆盖盲区快速搭建应急通信专网，为应急救援提供高效、稳定的通导业务保障手段。因此，本研究针对差异化的应急救援需求，从移动公网增强与应急专网补盲的角度，开展智能应急通信与定位增强方法的研究。

在城市等人口密集应急场景中，由于应急指挥专网的承载能力和服务对象受限，亟需快速对公网进行增强，通过数据驱动的低开销信道反馈等手段压缩频谱占用，提升现场通信网络的可接入用户数量。针对应急现场信道测量成本高、时间长，而缺乏充足的信道测量数据使得信道反馈模型在新的环境中模型精度显著下降的问题，本研究提出了差异化环境中基于有限测量样本的信道反馈模型性能增强方案，通过领域知识驱动的数据增强，支撑信道反馈模型在小样本训练集上的性能提升；在此基础上，结合球面归一化和深度展开构造了用于预训练的鲁棒骨干模型，进而设计了轻量化可插拔信道翻译模块，通过信道特征翻译高效复用预训练模型，在保障信道环境变化后反馈精度的同时显著降低模型更新开销，高效降低人口密集应急环境下的信道测量与模型部署成本。

在山地林区等恶劣环境下，救援任务常面临网络服务需求多样、救援力量高度机动等挑战，亟需快速灵活地调度应急专网为现场人员提供稳定的补盲网络覆盖与通导业务支持。针对应急现场人员移动引发的通信网络覆盖率与定位精度下降问题，本研究聚焦无人机辅助的动态应急网络调整，提出了基于虚拟力模型的应急通导网络动态适配方案，通过将通信需求与定位需求建模为地面用户对无人机基站的虚拟引力，支撑通导需求驱动的无人机位置调整；在此基础上，为了规避山地等障碍物遮挡导致的强衰落非视距链路，本研究提出了非视距链路规避引力建模方案，通过消除强衰落链路提升应急网络服务质量；进一步地，针对无人机与障碍物以及无人机之间的避撞需求进行了虚拟斥力建模；最后，基于虚拟合力设计了无人机能量自适应的部署位置适配方案，支撑动态适配方案的快速输出与无人机网络的长效覆盖。

关键词：应急通信，信道反馈，通导增强，动态部署



## Abstract

In emergency scenarios such as natural disaster response and accident disaster rescue, on-site personnel often face complex environments, loss of public networks, and satellite denial, leading to communication difficulties and inaccurate positioning. Establishing a new intelligent emergency communication network to support rapid blind spot filling and resilient recovery of emergency field networks and provide communication transmission and positioning service guarantees is crucial for improving disaster relief capabilities. However, emergency on-site rescue presents a variety of disaster types and complex geographical environments, which pose differentiated demands for intelligent emergency communication networks. In densely populated areas, there is a need to timely recover and enhance mobile communication public networks, assisting the public in promptly reporting information and seeking help in emergencies. In harsh environments such as mountainous forest areas, there is a need to quickly establish emergency dedicated networks for blind spot coverage in areas awaiting rescue after a disaster, providing efficient and stable communication and localization service guarantees for emergency rescue. Therefore, this study focuses on the differentiated emergency rescue needs, from the perspectives of public network enhancement and blind spot coverage by emergency dedicated networks, to conduct research on methods of enhancing intelligent emergency communication and localization.

In urban and other densely populated emergency scenarios, due to the limited carrying capacity and service objects of emergency command private networks, it is urgent to quickly recover and enhance public networks to improve support for on-site personnel information reporting and emergency assistance. Through data-driven low-overhead channel feedback and other means to compress spectrum usage, the number of users that the on-site communication network can accommodate is increased. Faced with the problem of high cost and long time for channel measurement at the emergency site, and the lack of sufficient channel measurement data causing a significant decline in model accuracy in new environments, this study proposes a performance enhancement scheme for channel feedback models based on limited measurement samples in differentiated environments. By driving data augmentation with domain knowledge, this supports the performance improvement of the channel feedback model on a small sample training set. On this basis, combining spherical normalization and deep unfolding, a robust backbone model for pre-training is constructed. A lightweight pluggable CSI translation module is then designed, which effectively reuses the pre-trained model through channel

feature translation, significantly reducing model update overhead while ensuring feedback accuracy after channel environment changes. This effectively reduces channel measurement and model deployment costs in densely populated emergency environments.

In harsh environments such as mountainous forest areas, rescue tasks often face challenges such as diverse network service demands and highly mobile rescue users. There is an urgent need to quickly and flexibly dispatch emergency dedicated networks to provide stable blind spot network coverage and localization services for on-site personnel. In response to the decline in communication network coverage and positioning accuracy caused by the movement of emergency personnel on site, this study focuses on UAV-assisted dynamic emergency network adjustment, and proposes a virtual force model-based emergency guidance network dynamic adaptation scheme. By modeling communication and positioning demands as virtual gravitational pull from ground users to UAV base stations, this supports UAV position adjustment driven by communication and localization requirements. On this basis, in order to avoid the severe attenuation and non-line-of-sight links caused by obstructions such as mountains, this study proposes a non-line-of-sight link avoidance force modeling scheme, which improves the quality of emergency network services by eliminating severely attenuated links. Furthermore, virtual repulsive force modeling is carried out for the collision avoidance needs between UAVs and obstacles and among UAVs. Finally, a UAV energy adaptive deployment position adaptation scheme is designed based on virtual resultant forces, supporting rapid output of dynamic adaptation schemes and long-term coverage of UAV networks.

Keywords: Emergency communication, channel feedback, communication and localization enhancement, dynamic deployment.

# 目录

目录.....	7
1 绪论.....	9
1.1 研究意义.....	9
1.2 研究挑战.....	10
1.3 国内外研究现状.....	12
1.3.1 低开销信道反馈.....	12
1.3.2 通导网络部署.....	14
1.4 研究内容.....	15
1.5 课题来源.....	16
参考文献.....	18
2 面向差异化环境小样本数据的鲁棒 CSI 反馈.....	21
2.1 引言.....	21
2.2 系统模型.....	23
2.3 总体框架.....	25
2.4 骨干反馈网络 SPTM2-ISTANet+ .....	26
2.4.1 编码网络.....	26
2.4.2 解码网络.....	27
2.5 CSI 翻译架构 CSI-TransNet .....	29
2.6 模型驱动的数据增强.....	31
2.7 仿真结果与性能分析.....	33
2.7.1 参数设定.....	33
2.7.2 锚模型的反馈精度对比.....	34
2.7.3 数据增强性能对比.....	35
2.7.4 针对新场景的 CSI 反馈性能对比.....	36
2.7.5 复杂度对比.....	38
2.8 小结.....	39
参考文献.....	40
3 面向移动应急场景的动态通导网络适配.....	43
3.1 引言.....	43
3.2 系统模型.....	45

3.2.1 信道模型.....	45
3.2.2 定位模型.....	46
3.2.3 无人机能耗模型.....	47
3.3 问题建模.....	48
3.4 基于虚拟力模型的通导网络部署.....	49
3.5 仿真结果与性能分析.....	57
3.5.1 仿真设置.....	57
3.5.2 存在非视距遮挡的通导耦合场景仿真结果分析.....	58
3.5.3 无非视距遮挡的通导耦合场景仿真结果分析.....	61
3.5.4 存在非视距遮挡的通信保障场景仿真结果分析.....	63
3.6 小结.....	66
参考文献.....	67
4 总结.....	70

# 1 緒論

## 1.1 研究意义

我国是世界上受自然灾害与事故灾难影响最为严重的国家之一，总体上呈现灾害种类多、影响地域广、灾害损失重等特征。在自然灾害处置、事故灾难救援等应急场景中，现场人员往往面临着环境复杂、公网缺损、卫星拒止的情况，导致了通信不畅、定位不准、救援受阻等问题。2021年7月20日郑州市普降大暴雨、特大暴雨，因洪灾退服基站3.52万个，占基站总数的45%，受影响的移动网用户数38.2万户，导致大量区域无网或信号微弱。2019年3月30日，四川省凉山州发生森林火灾，扑火人员未及时探测到灾情现状，突遇山火爆燃，而灾区无公网信号覆盖、卫星信号遮挡严重，二次灾变未能及时感知上报，指挥中心救援指令下达滞后，导致30名消防员失联失踪遇难。应急通信保障是高效实施突发事件处置和精准救援的关键环节，“十四五”规划和2035年远景目标纲要中指出要“完善国家应急管理体系，加强极端条件应急救援通信能力建设”，二十大报告中将“完善应急管理体系，提高防灾减灾救灾和急难险重突发公共事件处置保障能力”列为了国家重要战略任务。面向应急救援需求优化与增强通信网络，支持应急现场网络的快速补盲与弹性恢复，提供通信传输和定位服务保障，对提高减灾救灾能力至关重要。

当前，如何将应急通信和网络技术引入救援中，减少人员伤亡和经济损失，任重道远。随着新一代信息技术的发展，灾害事故应急向智慧化发展已成为国际趋势，美国、欧洲、日本等发达国家和地区都在积极发展智慧应急，如英国国民紧急事务秘书处的中央警报系统和弹性直接网络（Resilience Direct），覆盖欧盟全部成员国的“112”应急联动系统等，在应急网络构建方面已取得成果。其中美国国家应急通信办公室与商务部、司法部经国会授权于2012年开始开发和构建全国范围的应急救援网络FirstNet，该网络结合5G、大数据及人工智能技术，提供多种车载临时通信组网方案，并在未来规划中，将实现网络通信-定位智能化服务、提升应急救援的有效性与可靠性作为发展目标。利用新一代信息技术赋能智慧应急，构建快速响应、可靠传输、智能感知、精准定位、综合保障的高效应急保障网络已成为国际共识。

我国目前以应急管理部为主导建立了以指挥信息网为核心的骨干网，主要包含卫星网络、无人机网络和地面网络，构建应急专网以提供上传下达通信保障能力。此外，以中国移动为代表的运营商设计了5G立体化指挥通信防控平台，通过小型无人机、高清图像采录设备、增强现实警用眼镜等智能终端与5G网络的连接，即时将灾害现场画面回传到应急管理指挥中心，助力指挥中心掌握现场情况。然而，应急现场救援存在灾情种类多、地理环境复杂的特点，对智能应急通信与定位业务保障提出了差异化的需求。一方面，需要针对灾害发生后的网络覆盖盲区快速搭建应急通信专网，为救援力量提供稳定、高效的通信和定位手段，保障信息传输的及时性，提高应急响应的效率。另一方面，由于应急通信专网的承载能力和服务对象受限，有必要及时恢复与增强移动通信公网，提升灾害发生后受灾人员主动接入网络寻求救助的保障能力。因此，为了满足应急现场的差异化通导保障需求，需要从应急专网补盲与公网恢复增强的角度，开展智能应急通信与定位增强方法研究。

## 1.2 研究挑战

在自然灾害与事故灾害发生后的减灾救灾中，我国应急通信网络面临的挑战主要体现在以下两个方面：（1）在专网应急层面，通信、导航网络分立设计且拓扑固化，复杂环境下通导性能影响因素多，难以高效灵活部署以响应快速变化的人员位置与通导需求。（2）在公网应急层面，现有移动通信网络缺乏灾害发生后的韧性接入和弹性设计，无法满足大量受灾人员主动接入网络上报灾情和寻求救援的迫切需求，难以及时调度有限救援力量实施精准应急救援。

具体地，在山地林区等恶劣环境下的应急救援中，前突侦察、救援处置等业务对应急通信网络提出了新的发展要求，由传统仅保障指挥信息的上传下达转变为定位导航、通信保障、辅助决策等多能力要求。以山地森林火灾为例，在前突侦察阶段，需要提供远距离大范围的受灾人员定位能力以进行精准救援；在救援处置阶段，需要根据指挥业务需求保障文本、语音、图像等数据的稳定传输，并提供导航服务进行辅助支持。然而，现有应急通信专网拓扑固化且通信、导航网络分立设计，难以高效灵活部署以响应快速变化的用户分布和通导需求，尤其是在林区等环境的应急救援，由于其环境恶劣、车辆难行，对应急指挥通信网络的快速部署带来了极大的挑战。尽管无人机辅助的应急网络能为高效地应对复杂环境下的应急基站灵活调度需求，但是当前

中心启发式算法驱动的应急网络部署方案复杂度高、求解时间长，难以及时适配快速变化的应急现场情况；此外，无人机网络受续航能力的约束导致应急网络可持续服务时间高度受限，亟需在保障应急通导需求的前提下提升能量效率与服务时间。针对上述挑战，有必要从多能通导网络动态适配的角度开展应急专网增强的研究，保障应急网络适配方案的快速输出与无人机网络的长效覆盖。

另一方面，在重大自然灾害发生后，现有移动通信网络常面临大量基础设施退出服务与损坏，且难以短时间内完成抢修与恢复，使得受灾人员接入网络寻求救援困难。2021年7月郑州市特大暴雨后经过3天抢修，退服基站仍占总数的10.5%，导致部分区域内受灾用户长时间难以接入移动通信网络。当部分基站退服且难以快速修复的情况下，为了满足更多受灾用户的通信需求，剩余基站将面临频谱资源匮乏的挑战，其中大规模多输入多输出（Multiple-Input and Multiple-Output, MIMO）天线对应的高维信道信息获取作为5G通信不可或缺的一部分占用了大量的频谱开销，如何优化现有信道获取方案以容纳更多的用户通信接入亟待解决。数据驱动的深度学习方案在信道获取中展现了有效的性能提升，但是在实际应用中，深度学习模型泛化性差、信道测量成本高、时间长，使得难以在应急救援中快速构建包含大量信道测量数据的训练集并及时适配不同位置的信道环境，而缺乏泛化性的模型和有限样本的训练集将导致用户区域变动后模型性能的明显下降。针对上述挑战，有必要从信道反馈跨区域适配的角度开展应急公网增强的研究，保障公网信令信息的高精度压缩获取，支撑差异化应急环境下的低开销跨区域模型更新。



图 1-1 应急现场组网需求

## 1.3 国内外研究现状

以下将针对应急通信网络中的挑战，从低开销信道反馈和通导网络部署两个方面进行相关研究现状阐述。

### 1.3.1 低开销信道反馈

在我国城市区域通信中，5G 网络已成为主要覆盖网络之一。为了保障大型应急场景中受灾受困群众通信覆盖，特别是针对所在区域基站受损退服受困用户的通信需求，可利用 5G 基站的高谱效、大连接特性，智能降低在服基站信道获取开销以提升接入用户数量，扩展周边区域基站的服务范围和接入容量，为受灾受困用户提供通信支撑。

5G 网络主要支持两种通信模式，时分双工（Time Division Duplexing, TDD）和频分双工（Frequency Division Duplexing, FDD）。其中 FDD 模式由于其更大的覆盖范围、更强的抗干扰能力、对高速移动的支持和对复杂电磁环境的适应能力等，更适用于应急通信场景。根据高通研究报告[1]，TDD 系统需要比 FDD 系统多 65% 的基站才能实现相似的覆盖范围和性能。目前，我国工业和信息化部已将 700MHz FDD 频段划归中国广电 5G 网络使用，以及将 1.9/2.1GHz FDD 频段划归中国联通和中国电信 5G 网络使用[2]。5G 基站需要基于准确的信道信息来进行预编码等信道自适应传输以获取频谱效率的大幅提升，FDD 5G 系统的主要挑战是信道获取开销较大。对于城市公网应急通信而言，亟需在满足信道自适应传输所需信道获取精度的前提下高效降低高维信道的获取开销。

为了实现 FDD 模式下大规模 MIMO 基站信道状态信息（Channel State Information, CSI）的低开销获取，国内外研究人员从压缩信道反馈开销的角度出发设计了高维 CSI 压缩方案。其中，深度学习由于其在总结和提取数据规律和内在联系的卓越能力，近年来在工业界和学术界吸引了大量的研究兴趣。文献[3]首次提出了基于深度学习的大规模 MIMO 信道状态信息反馈架构 CsiNet，通过使用深度自编码器以及端到端的优化，取得了比传统压缩感知方案更好的反馈精度和重构速度。在此基础上，文献[4]和[5]分别通过设计多分辨率结构和超分辨率结构等网络结构优化方案提升 CSI 反馈性能。文献[6]和[7]进一步通过挖掘大规模 MIMO 信道的上下行相关性以压缩反馈中的冗余信息，有限提升相同反馈开销下的 CSI 恢复精度。然而，上述方案在复杂室外场景下的反馈精度相对于室内场景明显下降。因此，文献[8]通过利用相干时间内大规模 MIMO 信道的

时域相关特性，使用长短时记忆网络挖掘先前 CSI 反馈中的先验信息，明显提升室外场景下的 CSI 反馈精度。文献[9]利用上下行信道相关性，联合优化了信道估计的导频设计和信道压缩反馈，但该工作主要考虑了单载波下的导频信号功率分配，并未考虑目前实际应用中的导频在天线域和时频域的稀疏设计。因此，如何针对复杂城市场景的高动态信道，结合无线通信理论和人工智能技术，充分挖掘大规模 MIMO 信道在时-频-空域的相关性，在有限的算力和存储空间的约束下信道反馈以明显降低信道获取开销和容纳更多接入用户，仍是亟待解决的问题。

尽管基于人工智能的信道获取方案相对于传统方案能够获得明显的开销降低，但现有深度学习模型需要收集大量的无线信道样本来挖掘隐藏特征和提升模型精度，由此提升了深度学习方案城市应急场景中的应用成本。为了降低信道数据的获取成本，文献[10]和[11]分别针对单输入单输出（Single Input Single Output, SISO）和时域 MIMO 信道提出了基于生成对抗网络（Generative Adversarial Network, GAN）的信道数据生成方案，通过学习已有信道数据的统计分布来生成新的数据。文献[12]对比了图像处理领域的传统数据增强方案和 GAN 网络方案在不同反馈带宽下对 MIMO 信道反馈性能的影响，并展示了 GAN 网络方案可以带来更高信道恢复精度提升。然而，GAN 网络的性能仍然依赖于真实信道数据的规模，在应急场景下 5G 宽带大规模 MIMO 系统的应用中面临挑战。文献[13]针对 MIMO 信道估计设计了基于深度自编码器的信道数据增强方法，通过在编码器输出的码字中添加高斯白噪声之后解码来进行信道数据增强。然而，该方法难以良好的捕捉信道特征，仅在真实测量数据集大小小于特定阈值时才能带来信道估计性能提升，当真实数据集超过阈值后甚至会因为生成信道数据的影响而降低信道估计性能。此外，现有研究通常从基于有限信道测量数据生成更多虚拟数据的角度出发，并未针对如何针对有限样本数据集设计更为鲁棒的神经网络结构展开研究。因此，如何针对复杂城市应急场景的高维信道智能低开销获取，设计高效的信道数据增强方案以及鲁棒信道获取模型，实现有限的信道测量样本下高精度模型训练，仍是亟待解决的问题。

综上所述，针对信道压缩获取问题，现有研究缺乏对城市应急救援场景中有限现场测量样本和容纳更多新增受灾用户接入的考虑。因此，本报告将面向人口密集应急场景，深入挖掘高维信道的多域相关性，设计有限信道测量样本下的复杂高维信道智能低开销获取方案。

### 1.3.2 通导网络部署

为了满足山地林区等恶劣环境下的指挥通信需求，针对不同的受灾情况，需快速构建空中组网、空地协同组网进行精准通信补盲。然而，在实际救援行动中，不同用户的业务需求不同，用户的位置也会随着救援行动的进展动态变化。如何利用有限的资源优化网络部署，满足不同用户通信和定位需求的同时兼具网络动态调整的特性，是研究的关键问题。研究人员针对传感数据与人员分布信息采集、定位与通信需求高效保障和基站位置动态调整等问题展开了相关研究。

在传感数据与人员分布信息采集方面，文献[14]提出了一种基于多无人机的无线传感器网络框架设计，首先将结合传感器地理分布划分若干簇来汇聚数据，并通过优化簇头的数量和位置保障传感数据完整采集，进而优化无人机飞行轨迹来降低飞行路径长度。文献[15]将基于无人机的传感器数据收集问题转化为旅行商问题，进而通过遗传算法求解无人机的飞行轨迹。文献[16]提出了一种智能强化学习方法，通过结合经验回放训练双深度 Q 网络学习动态场景下无人机控制策略，用于在城市环境中从物联网设备中收集数据。文献[17]利用单个无人机进行圆周运动作为定位锚点，并在飞行能量的约束下探究了航路点的数量、悬停时间和飞行高度等轨迹影响因素的权衡，进而优化无人机轨迹以减低搜寻定位误差。文献[18]基于强化学习算法设计面向定位增强的单个无人机自主轨迹规划方案，在飞行能量的约束下进一步降低地面用户平均定位误差。上述研究可以协助网络部署决策提供先验参考信息，但仍需要进一步高效调度有限的应急设备为现场人员与救援行动提供稳定的补盲网络覆盖与通导业务支持。

在定位需求保障方面，文献[19]针对无人机辅助车辆定位场景，提出了一种基于资源分配的无人机部署方法，将问题拆分为无人机部署和资源优化两个子问题迭代求解，分别利用遗传算法和泰勒线性化近似算法求解部署和资源调度问题，最终得到一种高精度无人机定位组网。文献[20]围绕灾害场景中的无人机定位问题，提出了一种针对网络和电力中断状态下的无人机自主定位搜救方案，采用聚类搜索方法减少待定位节点个数和最小化无人机部署能耗。

在通信需求保障方面，文献[21]提出了一种基于机器学习框架的无人机位置优化算法，利用云端网络预测地面用户的位置分布和内容请求，在此基础上优化无人机部署位置，最小化无人机的发射功率，同时最大化用户的服务质量。文献[22]提出了一种实现多架无人机三维部署和动态运动的方法，利用基于 K-means 的遗传算法来获得用户的单

元划分并基于 Q-Learning 对无人机的静态部署与动态移动进行优化。文献[23]提出了面向差异化用户分布的能耗最小化部署方案。然而，现有研究大都是单独考虑通信或导航业务的资源优化，且信道模型未考虑林区信道特性，使得现有方案在山地林区环境下的性能难以保障。如何在山地林区环境下部署通导协同无人机组网，仍是亟待解决的问题。

在动态网络调整方面，文献[24]面向移动用户不断变化的瞬时流量需求，提出了一种无人机辅助通信网络的自适应部署方案。该方案重点针对呈泊松分布的随机用户，以优先服务用户数量最多的扇区为原则自适应调整无人机移动方向，以最大化平均吞吐量和成功传输概率优化位移距离，并在在用户密度较低的情况下取得由于传统非自适应方案的性能。文献[25]面向大型环境中移动用户的通信服务保障，采用了基于 3D 卷积深度强化学习的区块选择算法和基于能源感知深度强化学习的区块搜索算法，在提升系统吞吐量和网络服务时间上取得了显著的效果。文献[26]研究了如何通过优化无人机的位置，实现在覆盖所有地面移动终端的同时最大化实时下行链路容量。该文献将无人机网络动态调整问题为受限马尔可夫决策过程，并采用 Q 学习和引入神经网络与对抗结构的 Dueling Deep Q-network 算法来求解，实现了有效的地面移动终端追踪覆盖。然而，不同于上述研究，在山地林区等场景下信道环境更加复杂且存在山体等强衰落遮挡需要规避，同时需要针对应急救援业务保障需求快速输出动态网络调度策略。

综上所述，针对应急救援现场用户通导需求多元和位置分布动态的问题，现有研究欠缺对通导耦合网络的拓扑设计、快速调度的联合考虑难以高效适配有限应急资源下的高效通导覆盖补盲需求。因此，本研究将基于无人机基站辅助的应急网络，设计高能效动态通导网络适配方案。

## 1.4 研究内容

本研究针对高效应急救援与可靠组网需求，以实现应急现场的通信能力与定位精度高效保障为目标，从公网恢复增强与应急专网补盲的角度，将智能信号处理、无线通信、优化理论等融合到应急通信系统，面向压缩传输和动态覆盖等业务需求，从以下两方面开展智能应急通信与定位增强的研究：

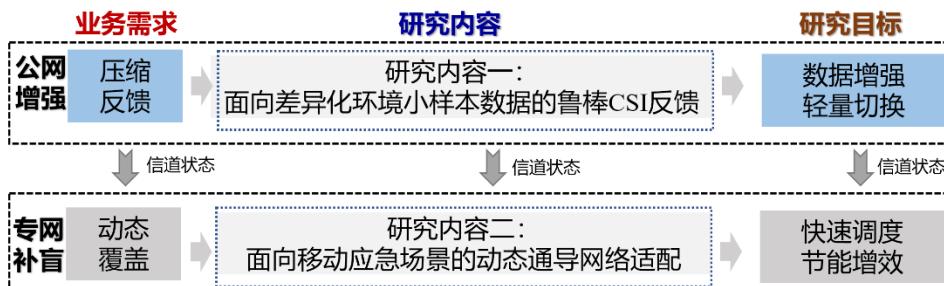


图 1-2 研究内容结构图

1) 针对城市等人口密集应急场景下部分基础设施损坏，需要通过信道压缩反馈等手段提升可用基站的频谱利用率，而信道反馈模型在环境变化后性能显著下降，应急现场信道测量成本高、时间长、缺乏充足的信道测量数据进行模型优化的问题，研究差异化环境中有限测量样本下的信道反馈模型性能增强方案。通过设计领域知识驱动的数据增强策略，实现信道反馈模型在小样本数据集上的性能提升，进而设计了轻量化可插拔 CSI 翻译模块，通过信道数据特征变换支持在全新的环境中预训练模型的高精度复用，同时大幅降低模型更新的传输开销，为人口密集应急场景下的新增用户增加可接入空间。

2) 针对应急现场网络服务需求灵活多变、救援力量高度机动，难以在动态场景下稳定保障通信网络覆盖与定位精度的问题，研究基于虚拟力模型的应急通导网络动态适配方案，支撑动态场景下的通导网络稳定覆盖。通过将通信需求与定位需求建模为地面用户的虚拟引力，将山体遮挡导致的强衰落链路规避需求建模为虚拟引力，将无人机避障需求建模为虚拟斥力，进而基于无人机所受合力与剩余能量设计了高能效无人机部署位置优化方案，支撑动态适配策略的快速输出，在保障应急网络高效覆盖的前提下有效提升无人机网络工作时间。

## 1.5 课题来源

- 1) 国家重点研发计划项目课题一“通导指一体化应急网络架构及高动态可靠组网”(编号：2020YFC1511801)；
- 2) 北京市自然科学基金-海淀原始创新联合基金项目“无人机辅助的智能应急边缘网络理论与关键技术研究”(编号：L192030)；

3) 国家自然科学基金青年科学基金项目“城市应急中基于高维信道认知的通信定位协作增强理论与方法”(编号: 62201089)。

## 参考文献

- [1] Qualcomm Inc. Fdd/tdd comparison – key messages.  
<https://www.qualcomm.com/documents/fddtdd-comparison>, 2013.
- [2] 无线电管理局,工信部已向四家基础电信运营企业许可的移动通信频段统计,  
[https://wap.miit.gov.cn/jgsj/wgj/kpzs/art/2021/art\\_9105abf8095d49bd9065c1b6ebb06d2a.html](https://wap.miit.gov.cn/jgsj/wgj/kpzs/art/2021/art_9105abf8095d49bd9065c1b6ebb06d2a.html), 2021.
- [3] Wen C, Shih W, Jin S. Deep Learning for Massive MIMO CSI Feedback[J]. IEEE Wireless Communications Letters, 2018, 7(5): 748-751.
- [4] Lu Z, Wang J, Song J. Multi-resolution CSI Feedback with Deep Learning in Massive MIMO System[C]. ICC 2020 - 2020 IEEE International Conference on Communications (ICC), 2020.
- [5] Chen X, Deng C, Zhou B, et al. High-Accuracy CSI Feedback With Super-Resolution Network for Massive MIMO Systems[J]. IEEE Wireless Communications Letters, 2022, 11(1): 141-145.
- [6] Liu Z, Zhang L, Ding Z. Exploiting Bi-Directional Channel Reciprocity in Deep Learning for Low Rate Massive MIMO CSI Feedback[J]. IEEE Wireless Communications Letters, 2019, 8(3): 889-892.
- [7] Lin Y-C, Liu Z, Lee T-S, et al. Deep Learning Phase Compression for MIMO CSI Feedback by Exploiting FDD Channel Reciprocity[J]. IEEE Wireless Communications Letters, 2021, 10(10): 2200-2204.
- [8] Wang T, Wen C, Jin S, et al. Deep Learning-Based CSI Feedback Approach for Time-Varying Massive MIMO Channels[J]. IEEE Wireless Communications Letters, 2019, 8(2): 416-419.
- [9] Guo J, Wen C-K, Jin S. CANet: Uplink-Aided Downlink Channel Acquisition in FDD Massive MIMO Using Deep Learning[J]. IEEE Transactions on Communications, 2022, 70(1): 199-214.
- [10] Yang Y, Li Y, Zhang W, Qin F, Zhu P, Wang C-X. Generative Adversarial-Network-Based Wireless Channel Modeling: Challenges and Opportunities[J]. IEEE Communications Magazine, 2019, 57(3): 22-27.
- [11] Xiao H, Tian W, Liu W, Shen J. ChannelGAN: Deep Learning-Based Channel Modeling and Generating[J]. IEEE Wireless Communications Letters, 2022, 11(3): 650-654.
- [12] Liang X, Liu Z, Chang H, Zhang L. Wireless Channel Data Augmentation for Artificial Intelligence of Things in Industrial Environment Using Generative Adversarial Networks[C]// 2020 IEEE 18th International Conference on Industrial Informatics (INDIN). 2020: 502-507.

- [13] Li L, Zhang Z, Yang L. Influence of Autoencoder-Based Data Augmentation on Deep Learning-Based Wireless Communication[J]. IEEE Wireless Communications Letters, 2021, 10(9): 2090-2093.
- [14] Alfattani S, Jaafar W, Yanikomeroglu H, Yongacoglu A. Multi-UAV Data Collection Framework for Wireless Sensor Networks[C]//2019 IEEE Global Communications Conference (GLOBECOM), Waikoloa, HI, USA, 2019: 1-6.
- [15] R. Amer, W. Saad and N. Marchetti. Mobility in the Sky: Performance and Mobility Analysis for Cellular-Connected UAVs[J]. IEEE Transactions on Communications, 2020, 68(5): 3229-3246.
- [16] Bayerlein H, Theile M, Caccamo M, et al. UAV Path Planning for Wireless Data Harvesting: A Deep Reinforcement Learning Approach [C]//2020 IEEE Global Communications Conference (GLOBECOM). 2020:1-6.
- [17] Sallouha H, Azari M M, Pollin S. Energy-Constrained UAV Trajectory Design for Ground Node Localization [C]//2018 IEEE Global Communications Conference (GLOBECOM). 2018:1-7.
- [18] Ebrahimi D, Sharafeddine S, Ho P -H, et al. Autonomous UAV Trajectory for Localizing Ground Objects: A Reinforcement Learning Approach [J]. IEEE Transactions on Mobile Computing, 2021, 20(4):1312-1324.
- [19] Yang J, Liang T, Zhang T. Deployment Optimization in UAV Aided Vehicle Localization[C]//2021 IEEE 93rd Vehicular Technology Conference (VTC2021-Spring). 2021: 1-6.
- [20] Atif M, Ahmad R, Ahmad W, et al. UAV-assisted wireless localization for search and rescue[J]. IEEE Systems Journal, 2021, 15(3): 3261-3272.
- [21] Mozaffari M, Saad W, Bennis M, et al. Efficient deployment of multiple unmanned aerial vehicles for optimal wireless coverage[J]. IEEE Communications Letters, 2016, 20(8): 1647-1650.
- [22] Liu X, Liu Y, Chen Y. Reinforcement learning in multiple-UAV networks: Deployment and movement design[J]. IEEE Transactions on Vehicular Technology, 2019, 68(8): 8036-8049.
- [23] M. Alzenad, A. El-Keyi, F. Lagum, and H. Yanikomeroglu, "3-D placement of an unmanned aerial vehicle base station for energy-efficient maximal coverage," IEEE Wireless Communications Letters, vol. 6, no. 4, pp. 434-437, Aug. 2017.
- [24] Wang Z, Duan L, Zhang R. Adaptive Deployment for UAV-Aided Communication Networks [J]. IEEE Transactions on Wireless Communications, 2019, 18(9):4531-4543.
- [25] Sun R, Zhao D, Ding L, Zhang J, Ma H. UAV-Net+: Effective and Energy-Efficient UAV Network Deployment for Extending Cell Tower Coverage With Dynamic Demands[J]. IEEE Transactions on Vehicular Technology, 2023, 72(1): 973-985.

- [26] Wang Q, Zhang W, Liu Y, Liu Y. Multi-UAV Dynamic Wireless Networking With Deep Reinforcement Learning[J]. IEEE Communications Letters, 2019, 23(12): 2243-2246.

## 2 面向差异化环境小样本数据的鲁棒 CSI 反馈

### 2.1 引言

在人口密集区域的减灾救灾中，现有应急通信网络缺乏公网的韧性接入和弹性设计，难以满足重大灾害发生后受灾人员主动接入网络上报受困位置和寻求救援的迫切需求，难以及时调度有限救援力量实施精准应急救援。其中在频谱层面，由于蜂窝网络频谱资源有限，在受灾区域部分基站损毁或退服的场景下，通过对可用基站的无线资源调度已无法满足超出原始限额受灾用户的大数量及高频率的应急信息可靠传输需求；5G 网络通过在基站架设大规模天线阵列，进而基于精准的信道估计与反馈获取的信道状态信息，利用波束赋形等信道自适应技术成倍提高频谱效率，然而大规模天线阵列的高维信道估计与反馈需要消耗大量的频谱资源，严重制约了应急现场移动网络可以接入的新增用户数量。

传统的矢量量化和基于码本的方法通过在 UE 侧量化 CSI 来减少反馈开销[1]。然而，随着天线数量的增加，反馈开销往往会增加，通常需要大量的上行带宽数或低精度的实际大规模 MIMO 无线传输。基于压缩感知（Compressive Sensing, CS）的方法利用信道在某些域中的稀疏性降低 CSI 反馈开销[2]。然而，基于 CS 的方法通常依赖于某些领域严格不满足的强信道稀疏条件。此外，迭代的 CS 重构方法可能需要大量的计算时间来准确恢复下行 CSI 估计。基于深度学习（Deep Learning, DL）的 CSI 反馈通过利用空间和频谱一致性[4]-[8]、双向互易性[9][10]以及时间相关性[11]-[13] 等特性，表现出良好的恢复精度。

尽管数据驱动的深度学习方案在低开销信道获取和提升应急场景中的可接入空间中展现了有效的频谱效率提升，但是每个场景下的深度学习模型训练需要大量的信道测量数据。在实际应用中，信道测量成本高、时间长，使得难以在应急救援现场快速构建包含大量信道测量数据的训练集，而有限样本的训练集将导致模型性能的明显下降。此外，基于深度学习的信道反馈方案具有较强的过拟合特性，常面临通信环境和信道分布变化后反馈精度严重下降的问题。因此，需要研究差异化环境中有限测量样本下的信道获取模型性能增强方案。

通过数据增强扩充少量测量数据用于深度学习训练可以大大降低劳动密集型测量的成本并减轻模型过拟合[14]。然而，图像处理中常用的传统数据增强技术，如几何变换、裁剪或旋转等，因为缺乏对信道特性的考量，与物理无线信道特性难以直接适配。另一种解决方案是使用生成对抗网络（Generative adversarial network, GAN）作为黑盒应用于 CSI 增强[15]-[17]。然而，GAN 本身通常需要大量的 CSI 数据进行训练。此外，面向大规模 MIMO 信道设计的 GAN 具有较高的计算复杂度，甚至需要数十亿次浮点运算（FLOPs）[17]。

除了数据增强之外，为了提高有限可用数据样本的 CSI 恢复精度，深度神经网络应能够处理复杂的 CSI 特征和变化。现有基于深度学习的 CSI 反馈工作[6][8][9]在室内信道上表现出较为精确的反馈性能，然而在更复杂的室外信道上则效果不佳。此外，大规模 MIMO 信道的 CSI 往往表现随着用户位置变化表现出较高的差异性。仅路径损耗就可以使 CSI 的幅度变化几个数量级。这种固有的 CSI 特性对于仅使用缺乏广泛性的小型数据集进行训练的基于深度学习的 CSI 压缩和反馈系统会造成严重的性能下降。因此，处理来自各种差异化信道环境下大规模 MIMO CSI 的能力是基于 DL 的 CSI 反馈方案在实际部署中面临的一项艰巨挑战。针对上述挑战，本研究提出了一种基于迁移学习原则的新训练机制。

迁移学习[18][19]利用不同场景中的跨任务相关性来降低训练成本。然而，对于 CSI 编码和压缩反馈问题，用户设备（User Equipment, UE）需要足够的内存来存储编码器 DNN 或频繁更新编码器 DNN 的参数，这通常需要大量的存储或传输带宽以支持编码器网络的适配，每个网络可能包含多达数百万个参数[4]-[8]。针对多个 CSI 场景，文献[20]提出了一种面向用户设备的多任务学习式 CSI 反馈设计。通过利用共享编码器和多个任务特定解码器，文献[20]的联合反馈架构可以降低用户设备对反馈模型的存储开销。然而，共享编码器会因为缺少部署环境的专有特征而降低 CSI 恢复精度。

为了在有限的 CSI 样本和部署成本下实现应急场景自适应且高精度的 CSI 反馈，本研究提出了一种利用轻量级翻译模型应对新信道环境下 CSI 反馈模型的高效训练和部署增强解决方案，并提出了一种基于领域知识的数据集增强方法。具体而言，本研究首先设计了一个深度展开的 CSI 反馈网络，SPTM2-ISTANet+，它采用球面归一化来解决路径损耗变化的挑战。本研究还在 SPTM2-ISTANet+ 中引入了一个可训练的测量矩阵和残差 CSI 恢复块的集成，以提高效率和准确性。基于 SPTM2-ISTANet+ 作为锚反馈模型，本研究提出了一种高效的场景自适应 CSI 反馈架构 CSI-TransNet。该架构利用

了一个由稀疏对齐功能和轻量级 DL 模块组成的可插拔 CSI 翻译模块，保障在未见过的环境中高效重用预训练模型，从而大幅降低模型更新开销。为了应对小数据集的挑战，本研究提出了一种基于领域知识的轻量级信道数据增强策略。实验结果表明所提出解决方案在仅需 200 个信道测量样本的情况下即可多变的 CSI 环境提供准确的信道反馈。

## 2.2 系统模型

不失一般性，本研究考虑一个装有  $N_b$  个天线的大规模 MIMO gNB，用于为其覆盖范围内的多个单天线用户设备（UE）提供服务。在下行传输中采用正交频分复用（OFDM）技术，在  $N_f$  个子载波上进行传输。对于子载波  $m$ ，令  $\mathbf{h}_m \in \mathbb{C}^{N_b \times 1}$  表示信道向量， $\mathbf{w}_m \in \mathbb{C}^{N_b \times 1}$  表示预编码向量， $x_m \in \mathbb{C}$  表示传输的数据符号， $n_m \in \mathbb{C}$  表示附加噪声。相应地，用户设备接收到的信号为

$$y_m = \mathbf{h}_m^H \mathbf{w}_m x_m + n_m, \quad (2-1)$$

其中  $(\cdot)^H$  表示共轭转置。则空间-频率域的下行信道状态信息矩阵可以表示为  $\mathbf{H} = [\mathbf{h}_1, \dots, \mathbf{h}_{N_f}]^H \in \mathbb{C}^{N_f \times N_b}$ 。为了减少反馈开销，本研究首先利用时延域中 CSI 的稀疏性，使用二维离散傅里叶变换（DFT）将空间-频率域的 CSI 矩阵  $\mathbf{H}_{sf}$  变换到角度-时延域的  $\mathbf{H}_{ad}$ ：

$$\mathbf{F}_d^H \mathbf{H}_{sf} \mathbf{F}_a = \mathbf{H}_{ad}, \quad (2-2)$$

其中， $\mathbf{F}_d$  和  $\mathbf{F}_a$  分别表示大小为  $N_f \times N_f$  和  $N_b \times N_b$  的 DFT 酎矩阵。由于实际无线环境中时延扩散和散射受到限制，大小为  $N_f \times N_b$  的矩阵  $\mathbf{H}_{ad}$  中除了前  $R_d$  行外的元素可以忽略不计[4]。因此，本研究通过保留  $\mathbf{H}_{ad}$  的前  $R_d$  行来近似 大规模MIMO 信道，并将其使用  $\mathbf{H}$  表示。

为了让基于 DL 的 CSI 反馈系统能够在不同环境下跟踪无线衰落信道的空间变化特性，移动网络运营商需要在每个环境中收集信道测量数据，并训练相应的 DL 网络。此外，进入新环境的 UEs 需要调整其编码器 DL 网络，该网络会具有数百万个参数。假设一个区域有  $T$  个典型场景，本研究可以使用  $\mathbf{H}^t$  表示场景  $t$  的信道矩阵。本研究的目标是减少在新环境中进行训练所需的信道测量数据量，并降低 CSI 反馈的 DL 模型部署成本。本研究从以下三个方面构建一个基于DL的小样本学习 CSI 反馈框架：

- 1) CSI 反馈的 DL 框架应在复杂信道环境下实现高精度恢复，这需要一个强大的解码

网络。此外，DL 反馈模型需要能应对信道环境变化。

- 2) 数据增强应有助于挖掘显著的 MIMO 信道特征，以降低所需信道测量的数量，并覆盖测量数据中可能缺失的情况。
- 3) 反馈模型应能利用已知信道环境中的先前训练结果，以降低训练复杂性和部署成本。

为了利用先前已知场景中的训练结果，本研究将 DL 反馈网络的设计分为两个阶段：a) 在没有先验信息的锚定场景中构建 DL 网络 ( $t = 1$ )；b) 通过利用先前训练阶段 a) 中学到的信息，为其他场景 ( $t = 2, 3, \dots, T$ ) 构建 DL 网络。

设  $\hat{\mathbf{H}}^t$  为解码器在场景  $t$  下恢复的 CSI 矩阵，对应于真实值  $\mathbf{H}^t$ 。定义编码和解码函数分别为  $f_{\text{en}}(\cdot)$  和  $f_{\text{de}}(\cdot)$ 。对于锚定场景中的下行链路 CSI 反馈结构，编码器网络和解码器网络分别可以表示为

$$\mathbf{s}_1 = f_{\text{en},1}(\mathbf{H}^1; \Phi_1), \quad (2-3)$$

$$\mathbf{H}^1 = f_{\text{de},1}(\mathbf{s}_1; \Psi_1). \quad (2-4)$$

对于后续场景  $t$  ( $t \geq 2$ )，编码器网络和解码器网络分别可以表示为：

$$\mathbf{s}_t = f_{\text{en},t}(\mathbf{H}^t; \Phi_t | \Phi_1, \Psi_1), \quad (2-5)$$

$$\mathbf{H}^t = f_{\text{de},t}(\mathbf{s}_t; \Psi_t | \Phi_1, \Psi_1). \quad (2-6)$$

基于上述编解码网络模型，本研究将构建基于深度学习的 CSI 反馈框架，以降低在多变环境中部署深度学习模型的成本，并通过使用有限信道测量数据训练的深度学习模型来改善 CSI 恢复。

## 2.3 总体框架

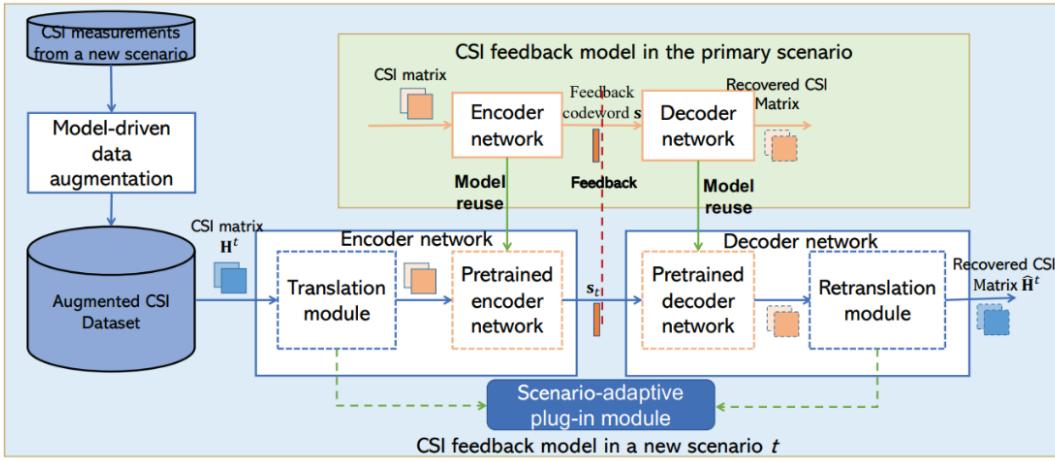


图 2-1 总体框架结构

如图 2-1 所示，本研究提出了一种场景自适应 CSI 反馈框架，该框架可以在新环境中复用预训练的高精度 CSI 反馈模型，同时集成了模型驱动的数据增强模块以应对小样本测量数据。总体框架包括以下三个模块：

- 1) 针对锚定场景训练的稳健骨干模型。关键思路是构建一个准确且稳健的骨干模型，以便在面临新环境时可以复用，从而降低部署成本。然而，大规模 MIMO 的 CSI 矩阵总是表现出很高程度的变化，并且随着 CSI 变化范围的扩大，反馈性能会明显下降[20]。因此，本研究构建了一种高效的压缩 CSI 反馈架构 SPTM2-ISTANet+，作为骨干网络以适应复杂的 CSI 特征和变化。SPTM2-ISTANet+由一个球面反馈结构和一个受压缩感知启发的 DNN 模型组成，以提高反馈的稳健性和准确性。SPTM2-ISTANet+ 的详细设计将在第四部分介绍。
- 2) 场景自适应可插拔模块。通过将新场景中的 CSI 矩阵转换为与预训练过程中锚定场景兼容的“样式”，可以复用预训练的骨干网络，并降低部署成本。因此，本研究提出了一个轻量级的场景自适应可插拔模块，仅包含几千个可针对新场景进行更新的可训练参数。该模块集成了一个翻译模块和一个重翻译模块，以实现 CSI 样式的翻译和恢复。样式转换器的详细设计将在第五部分介绍。
- 3) 模型驱动的数据增强模块。为了降低与劳动密集型信道测量相关的成本，本研究根据领域知识并利用 CSI 矩阵的物理特性，设计了一个简单但有效的模型驱动增强模块。鉴于信道相关特性，CSI 的幅度和相位分别进行增强。模型驱动数据增强的详细设计将在第六部分解释。

## 2.4 骨干反馈网络 SPTM2-ISTANet+

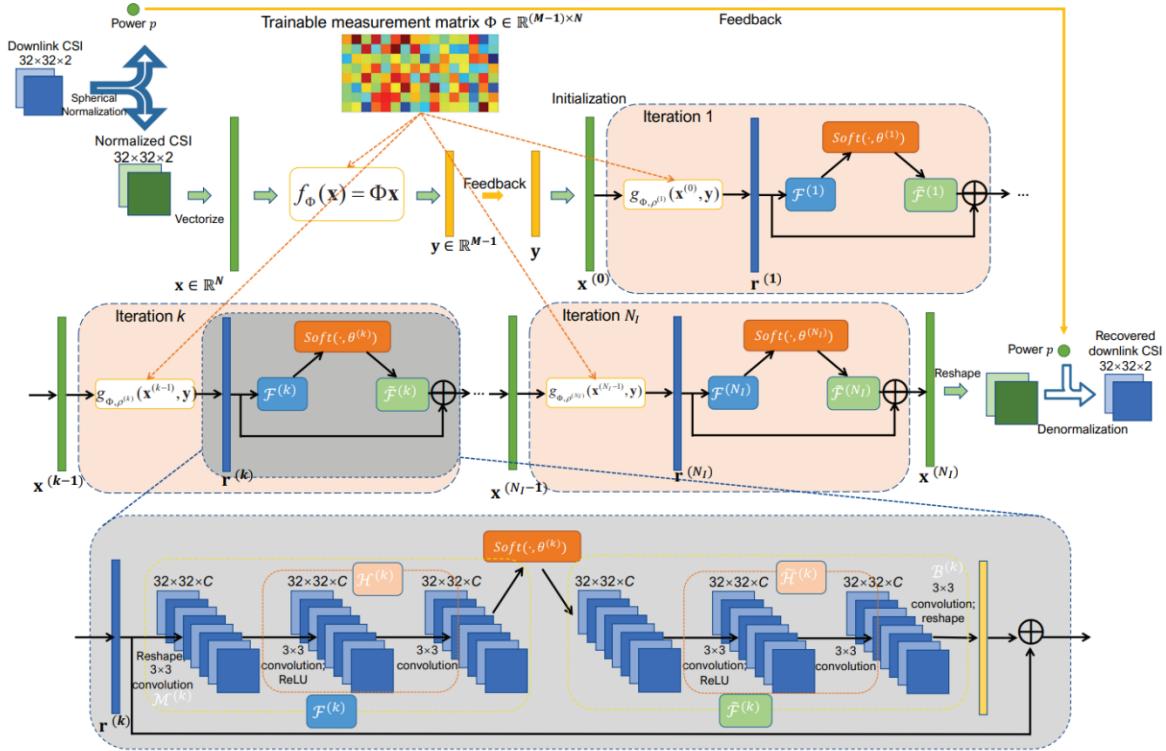


图 2-2 SPTM2-ISTANet+ 网络架构

本节构建了一个高效的深度展开网络作为锚定场景的骨干模型，以提高 CSI 反馈准确性。

### 2.4.1 编码网络

为了提高鲁棒性和 CSI 压缩效率，本研究采用基于深度展开的反馈网络，并针对物理 CSI 特征在编码器网络中提出两个关键创新。

首先，本研究根据无线电信道的领域特定特性，构建一个球面 CSI 反馈结构。MIMO CSI 系数的分布与图像数据的分布截然不同。由于无线电路径损耗，CSI 的动态范围总是更大，因为一个 UE 的 CSI 可能与另一个 UE 的 CSI 相差数个数量级。一般的归一化处理方法可能会使某些 UE 的 CSI 变得太小，导致较大的恢复误差。因此，在应用 CS 测量矩阵降低 CSI 维度之前，本研究将 CSI 矩阵  $\mathbf{H}$  分解为功率值  $p$  和球面矩阵  $\check{\mathbf{H}}$ ，其中  $p = \|\mathbf{H}\|$  是功率，而  $\check{\mathbf{H}} = \mathbf{H} / \|\mathbf{H}\|$  是单位球面的 CSI。

如图 2-2 所示，在球面处理化之后，本研究将归一化的下行链路 CSI 矩阵  $\check{\mathbf{H}}$  向量化为 DNN 的输入以进行压缩，并将复数 CSI 的实部和虚部分开以便于处理。相应的向量

表示为  $\mathbf{x} \in \mathbb{R}^N$ , 其中  $N = 2 \times R_d \times N_b$ 。为了缩短  $\mathbf{x}$ , 使用测量矩阵  $\Phi \in \mathbb{R}^{(M-1) \times N}$  进行维度压缩, 其中  $M = CR \times N - 1$ 。

其次, 为了进一步提高性能, 本研究摒弃传统的 CS 中随机构建测量矩阵, 设计一个数据驱动的可训练测量矩阵  $\Phi$ 。目标是更好地捕捉大规模 MIMO 的 CSI 编码特征, 尤其是在压缩程度高 (即 CR 较小) 的情况下。

## 2.4.2 解码网络

假设信道反馈过程是无损的[4][21], gNB 接收到的低维向量  $\mathbf{y} \in \mathbb{R}^{M-1}$  可表示为  $\mathbf{y} = \Phi \mathbf{x}$ 。基于  $\mathbf{y}$ , 解码器网络可以通过求解以下压缩感知恢复问题来重建原始的  $\mathbf{x}$ :

$$\min_{\mathbf{x}} \frac{1}{2} \| \Phi \mathbf{x} - \mathbf{y} \|^2 + \lambda \| F(\mathbf{x}) \|_1, \quad (2-7)$$

其中  $\lambda$  是正则化参数,  $\| \cdot \|$  表示  $l_2$ -范数,  $\| \cdot \|_1$  表示  $l_1$ -范数,  $F(\cdot)$  是  $\mathbf{x}$  的稀疏变换函数。

本研究提出的 SPTM2-ISTANet+ 解码器网络采用深度展开结构。采用 ISTANet+ [22] 的设置来展开迭代收缩阈值算法 (ISTA) [23], 本研究通过在两个步骤之间迭代来恢复 CSI:

$$\mathbf{r}^{(k)} = \mathbf{x}^{(k-1)} - \rho \Phi (\Phi \mathbf{x}^{(k-1)} - \mathbf{y}), \quad (2-8)$$

$$\mathbf{x}^{(k)} = \arg \min_{\mathbf{x}} \frac{1}{2} \| \mathbf{x} - \mathbf{r}^{(k)} \|^2 + \lambda \| F(\mathbf{x}) \|_1, \quad (2-9)$$

其中  $k$  表示迭代次数,  $\rho$  表示步长。接下来, 本研究分别将上述公式展开为模块  $\mathbf{r}^{(k)}$  和模块  $\mathbf{x}^{(k)}$ , 对应于第  $k$  次迭代的深度展开模块来解决重构问题。

模块  $\mathbf{r}^{(k)}$  基于第  $k-1$  次迭代的结果进行生成。为了提高恢复网络的灵活性, 模块  $\mathbf{r}^{(k)}$  中的步长  $\rho$  可以根据迭代次数自动调整, 即对于每个  $k$ ,  $\rho^{(k)}$  是可变的。因此, 模块  $\mathbf{r}^{(k)}$  可以被视为  $\mathbf{x}^{(k-1)}$  和  $\mathbf{y}$  的函数, 即:

$$\mathbf{r}^{(k)} = g_{\Phi, \rho^{(k)}} (\mathbf{x}^{(k-1)}, \mathbf{y}) = \mathbf{x}^{(k-1)} - \rho^{(k)} \Phi (\Phi \mathbf{x}^{(k-1)} - \mathbf{y}). \quad (2-10)$$

模块  $\mathbf{x}^{(k)}$  在第  $k$  次迭代中基于  $\mathbf{r}^{(k)}$  进行计算。在模块  $\mathbf{x}^{(k)}$  中, 用两个卷积层和一个 ReLU 单元  $\text{ReLU}(\mathbf{x}) = \max(0, \mathbf{x})$  来构建稀疏变换  $F(\cdot)$ , 即  $F(\mathbf{x}) = \mathbf{B} \cdot \text{ReLU}(\mathbf{A}\mathbf{x})$ , 其中  $\mathbf{A}$  和  $\mathbf{B}$  均使用无偏置的卷积层等效矩阵运算。为克服深度展开中常导致性能较差的梯度消失问题, 模块  $\mathbf{x}^{(k)}$  构建了残差结构以提高恢复精度。

假设  $\mathbf{x}^{(k)} = \mathbf{r}^{(k)} + \mathbf{w}^{(k)} + \mathbf{e}^{(k)}$ , 其中  $\mathbf{w}^{(k)}$  表示  $\mathbf{r}^{(k)}$  中缺失的高频分量,  $\mathbf{e}^{(k)}$  表示噪声。本研究应用线性操作  $\mathcal{R}(\cdot)$  从  $\mathbf{x}^{(k)}$  中提取缺失分量  $\mathbf{w}^{(k)}$ , 即  $\mathbf{w}^{(k)} = \mathcal{R}(\mathbf{x}^{(k)})$ 。定义  $\mathcal{R}(\cdot)$  为  $\mathcal{R} = \mathcal{B} \circ \mathcal{M}$ , 其中  $\mathcal{M}$  和  $\mathcal{B}$  对应于无偏置项的卷积层, 卷积核大小为  $3 \times 3$ 。注意, 当稀疏变换满足  $\mathcal{F}(\mathbf{x}) = \mathbf{B}\text{ReLU}(\mathbf{A}\mathbf{x})$  时, 以下公式近似成立:  $\|\mathcal{F}(\mathbf{x}) - \mathcal{F}(\mathbf{r}^{(k)})\|^2 \approx \alpha \|\mathbf{x} - \mathbf{r}^{(k)}\|^2$ [22], 其中  $\alpha$  是仅与变换  $\mathcal{F}(\cdot)$  的参数相关的标量。接下来, 将  $\mathcal{F}^{(k)}$  分解为  $\mathcal{F}^{(k)} = \mathcal{H}^{(k)} \circ \mathcal{M}^{(k)}$ , 其中  $\mathcal{H}^{(k)}$  由两个无偏置的卷积层加上ReLU激活组成。则模块  $\mathbf{x}^{(k)}$  的计算公式可以转换为

$$\mathbf{x}^{(k)} = \underset{\mathbf{x}}{\operatorname{argmin}} \frac{1}{2} \left\| \mathbf{H}^{(k)}(\mathbf{M}^{(k)}(\mathbf{x})) - \mathbf{H}^{(k)}\left(\mathbf{M}^{(k)}(\mathbf{r}^{(k)})\right) \right\|^2 + \theta^{(k)} \|\mathbf{H}^{(k)}(\mathbf{M}^{(k)}(\mathbf{x}))\|_1. \quad (2-11)$$

接下来, 构造  $\mathcal{H}^{(k)}(\cdot)$  的左逆函数, 使得  $\tilde{\mathbf{H}}^{(k)} \circ \mathbf{H}^{(k)} = \mathbf{I}$ , 其中  $\mathbf{I}$  是单位算子。然后本研究使用DNN构造  $\mathcal{H}^{(k)}(\cdot)$  的对称结构作为  $\tilde{\mathbf{H}}^{(k)}(\cdot)$ , 并将约束条件  $\tilde{\mathbf{H}}^{(k)} \circ \mathbf{H}^{(k)} = \mathbf{I}$  加入损失函数。最后,  $\mathbf{x}^{(k)}$  的闭合表达式可以表示为

$$\mathbf{x}^{(k)} = \mathbf{r}^{(k)} + \mathbf{B}^{(k)} \left[ \tilde{\mathbf{H}}^{(k)} \left[ \text{soft} \left[ \mathbf{H}^{(k)} \left( \mathbf{M}^{(k)}(\mathbf{r}^{(k)}) \right), \theta^{(k)} \right] \right] \right], \quad (2-12)$$

其中软阈值函数定义为  $\text{soft}(x, \theta) = \text{sgn}(x) \max(0, |x| - \theta)$ 。对应于模块  $\mathbf{x}^{(k)}$  的网络结构如图 2-2 中的灰色框所示。默认情况下, 内核数量  $C$  设置为 32。

为了优化SPTM2-ISTANet+中的参数, 本研究需要一个高效的训练损失函数。分别定义训练集的大小和第  $n$  个CSI向量为  $N_T$  和  $\mathbf{x}_n \in R^N$ 。定义迭代模块的数量为  $N_I$ 。本研究构建损失函数如下:

$$L_{\text{total}}(\Theta) = L_{\text{MSE}} + \gamma \cdot L_{\text{constraint}} \quad (2-13)$$

其中均方误差 (MSE)  $L_{\text{MSE}} = \frac{1}{N_T N} \sum_{n=1}^{N_T} \|\mathbf{x}_n^{(N_I)} - \mathbf{x}_n\|^2$  为CSI重建准确性指标,  $L_{\text{constraint}} = \frac{1}{N_T N} \sum_{n=1}^{N_T} \sum_{k=1}^{N_I} \|\tilde{\mathcal{H}}^{(k)} \left( \mathcal{H}^{(k)} \left( \mathcal{M}^{(k)}(\mathbf{r}_n^{(k)}) \right) \right) - \mathcal{M}^{(k)}(\mathbf{r}_n^{(k)})\|^2$  对应于  $\tilde{\mathbf{H}}^{(k)} \circ \mathbf{H}^{(k)} = \mathbf{I}$  限制, 其中  $\gamma$  是正则化权重 (除非另有说明, 否则设置为 0.01)。

## 2.5 CSI 翻译架构 CSI-TransNet

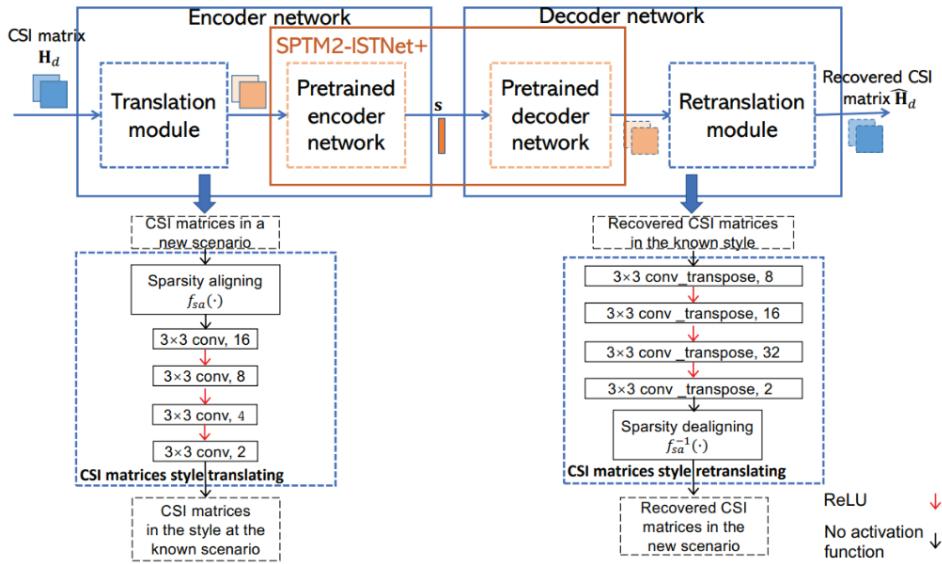


图 2-3 CSI-TransNet 网络架构

处理来自各种环境的CSI是实际部署基于深度学习的CSI反馈方案的关键挑战之一。一种解决方案是为每个场景或区域训练一个定制的网络，并根据UE检测到的信道环境动态切换到反馈网络。然而，这种解决方案要求UE具有足够的存储空间来保存许多深度编码器网络，而每个网络可能包含数百万个参数。另一种解决方案是UE通过下载新的模型参数频繁更新其编码器，但这种方案会在无线带宽和UE能量方面消耗高昂的成本。图像到图像翻译[24]已经应用于计算机视觉领域解决各种问题，包括图像风格化[25]和分割[26]等。它旨在学习可以将图像从源领域转换到目标领域的映射，同时保留输入图像的主要特征。例如，马的图像可以被转换成类似斑马风格的图像。受图像到图像翻译应用的启发，本研究通过将新场景中的CSI风格翻译成与给定已知场景CSI反馈模型相匹配的风格来提升模型的跨场景适应性。

在本节中提出了一种高效的CSI反馈架构“CSI-TransNet”，它在UE端集成了一个轻量级模块，以克服各种环境中基于深度学习的CSI模型的性能障碍。通过利用CSI到CSI的翻译，CSI-TransNet可以在新环境中重用具有高恢复精度的预训练CSI模型。

完整的CSI-TransNet架构如图 2-3所示，UE的编码器网络配备了一个翻译模块和一个共享的预训练编码器网络。gNB的解码器网络包含一个共享的预训练解码器网络和一个定制的重新翻译模块。需要注意的是，翻译和重新翻译模块是两个可插拔模块，它们只需要几千个参数，每当UE遇到新的信道环境时都可以轻松更新。CSI到CSI的翻

译使得经过翻译后的CSI矩阵更容易被预训练模型有效压缩和准确恢复，而无需进一步调整。因此，经过翻译后的CSI矩阵应具有与锚定场景中的CSI矩阵相似的性质。与基于数据的翻译不同，如图2-3所示，本研究在翻译模块的基于深度学习的翻译网络之前定制了一个稀疏性对齐函数，以实现轻量化的初步特征处理。

由于CSI矩阵在角度-时延域中是稀疏的[4]，本研究在新场景中将角度-时延域的循环移位应用于CSI矩阵，以促进与用于预训练锚模型的锚场景相似的稀疏性。定义稀疏对齐函数为 $f_{\text{sa}}(\cdot)$ ，定义循环移位函数为 $f_{\text{sh}}(\cdot, i, j)$ ，其中*i*和*j*分别表示行和列的移位步长。对于给定的CSI矩阵 $\mathbf{H}$ ，循环移位后的CSI矩阵元素 $\mathbf{H}^{\text{sh}} = f_{\text{sh}}(\mathbf{H}, i, j)$ 可以表示为

$$\mathbf{H}_{m,n}^{\text{sh}} = \mathbf{H}_{(m-i) \bmod R_d, (n-j) \bmod N_b}, \forall m \in [R_d], n \in [N_b]. \quad (2-14)$$

因此，稀疏对齐函数的目标是找到移位步长*i*和*j*以实现最佳相似性。实现这一目标的一种方法是计算两个场景的CSI幅值矩阵的最佳循环互相关[27]对应的移位步长。一种更严格且方便的方法是计算与预训练CSI反馈网络的最佳CSI恢复精度相对应的移位步长*i*和*j*，即

$$\min_{i,j} \left\{ \sum_n \left\| f_{\text{sh}}(\mathbf{H}_n, i, j) - f_{\text{de},1}(f_{\text{en},1}(f_{\text{sh}}(\mathbf{H}_n, i, j); \Phi_1); \Psi_1) \right\|^2 \right\}, \quad (2-15)$$

其中 $\mathbf{H}_n$ 对应于新信道场景中的第*n*个测量CSI矩阵。由于卷积层的平移不变性，本研究建议使用第二种方法来确定移位步长*i*和*j*。给定一对选定的移位步长*i*和*j*，本研究可以得到场景*t*中经过稀疏对齐后的CSI矩阵

$$\mathbf{H}^{\text{sa}} = f_{\text{sa}}(\mathbf{H}') = f_{\text{sh}}(\mathbf{H}', i, j). \quad (2-16)$$

在稀疏对齐之后，翻译模块的DNN包括4个卷积层，用于特征提取和翻译。具体来说，4个卷积层使用 $3 \times 3$ 的卷积核分别生成16、8、4和2个特征图。前3个卷积层使用ReLU激活函数。

重翻译模块的结构与翻译模块相反，首先构建一个DL网络对CSI矩阵进行微调，然后使用稀疏去对齐函数 $f_{\text{sa}}^{-1}(\cdot)$ 在新场景中恢复稀疏性。为了反转卷积，在重翻译模块中使用转置卷积层[28]。具体地说，4个转置卷积层使用 $3 \times 3$ 的卷积核分别生成32、16、8和2个特征图，前3个转置卷积层使用ReLU激活函数。使用与稀疏对齐相同的移位步长*i*和*j*可以恢复场景*t*中的CSI矩阵，即

$$\mathbf{H}' = f_{\text{sa}}^{-1}(\mathbf{H}^{\text{sa}}) = f_{\text{sh}}(\mathbf{H}^{\text{sa}}, -i, -j). \quad (2-17)$$

设 $\Theta_t$ 和 $\Omega_t$ 分别为翻译模块和重翻译模块中的DNN参数，相应的翻译函数4可以表示

为 $f_{\text{tra}}(\cdot; \Theta_t)$ ，重翻译函数可以表示为 $f_{\text{ret}}(\cdot; \Omega_t)$ 。对于场景 $t$ 中的CSI-TransNet，在确定移位步长 $i$ 和 $j$ 之后，本研究仅使用以下损失函数 $\mathcal{L}_{MSE}$ 共同训练可插拔模块 $f_{\text{tra}}(\cdot; \Theta_t)$ 和 $f_{\text{ret}}(\cdot; \Omega_t)$ 中的参数：

$$\frac{1}{N_t} \sum_n \left\| \mathbf{H}_n^{\text{sa}} - f_{\text{det},t}(f_{\text{de},1}(f_{\text{en},1}(f_{\text{tra},t}(\mathbf{H}_n^{\text{sa}}; \Theta_t); \Phi_1); \Psi_1); \Omega_t) \right\|^2, \quad (2-18)$$

其中 $N_t$ 是第 $t$ 个场景的训练CSI数据样本数量。

当UE检测并报告一个新场景时，CSI-TransNet架构中服务于该区域的gNB将发送翻译模块的权重到UE，以确保CSI反馈的准确性。由于CSI-TransNet的轻量级设计，需要更新的翻译模块只包含几千个参数，与编码器参数的总数相比有效降低了通信开销。

## 2.6 模型驱动的数据增强

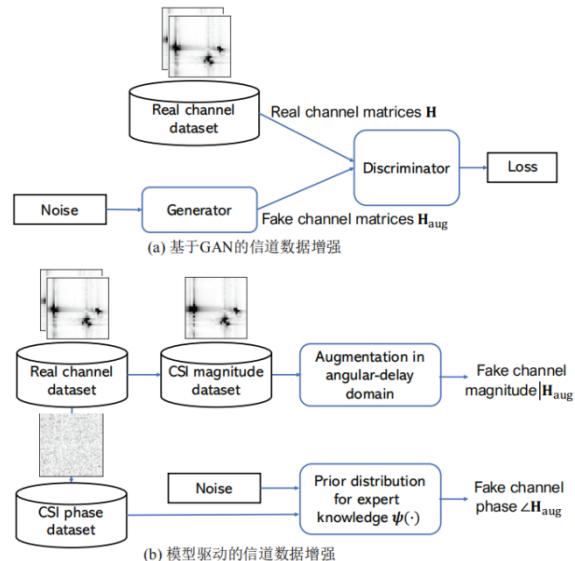


图 2-4 所提模型驱动的数据增强与基于GAN的数据增强之间的对比

除了降低在多变环境中部署CSI反馈模型的成本外，本节进一步考虑了在每个场景中需要数万个信道测量数据进行CSI反馈的DL模型训练的挑战，研究如何利用领域知识进行压缩CSI反馈和恢复的数据增强。

图 2-4(a)展示了一种传统的基于GAN的数据增强方法，在训练过程中交替求解最大化和最小化优化问题，以减小生成信道与真实信道分布之间的距离。生成器使用DNN将高斯噪声向量映射到生成伪信道数据。当GAN收敛以生成与真实信道匹配的分布的信道时，可以将GAN视为CSI模型的稳定存储，为支持CSI反馈网络训练生成大型训练数据集。然而，GAN本身需要足够的数据样本进行训练。此外，当可用的CSI测

量样本仅部分表示覆盖区域内的射频信道特征时，即使是经过良好训练的生成器也可能是一个分布偏差严重的信道模型，这可能进而显著降低使用生成的数据集训练的CSI反馈模型的性能。

为了增强CSI模型训练后的精度，本研究注意到增强样本应该呈现现有测量值中缺失或代表性不足的特征。本研究利用领域知识，通过解耦CSI矩阵的幅度和相位特征，提出了一种简单但有效的模型驱动的信道数据增强方案。

首先，本研究在增强前将MIMO信道矩阵的相位和幅度进行分离：

$$\mathbf{H} = |\mathbf{H}| \odot e^{j\angle \mathbf{H}}, \quad (2-19)$$

其中 $\odot$ 表示哈达马积。 $\mathbf{H}$ 的第 $(m, n)$ 项表示为 $\mathbf{H}_{m,n} = |\mathbf{H}_{m,n}| e^{j\angle \mathbf{H}_{m,n}}$ 。相应地，幅度CSI矩阵可以表示 $|\mathbf{H}|$ ，其元素为 $|\mathbf{H}_{m,n}|$ ，相位矩阵可以表示为 $\angle \mathbf{H}$ ，其元素为 $\angle \mathbf{H}_{m,n}$ 。幅值和相位的分离有助于应用关于CSI特征的领域知识，包括多径延迟特性和相位分布。

接下来，本研究利用CSI变化的地理连续性生成增强幅度矩阵，这些矩阵应该具有与测量信道相似的特征。在具有固定gNB和UE之间路径的典型环境中，现有研究表明地理连续的UE运动应该导致角度-延迟域中的平滑变化[29]。即由于到达/离开角度和多径传播延迟的相似性，角度-延迟域中测量点附近的CSI高度相关。因此，本研究可以通过循环地在角度-延迟域中移动CSI幅度矩阵来构建多个角度-延迟特征，生成反映附近UE CSI特征的新CSI矩阵。利用基于DFT性质的角度-延迟域中CSI矩阵的循环特性，信道幅度矩阵的数据增强需要使用循环移位。对于 $\forall m \in [R_d], n \in [N_b]$ ，增强幅度CSI矩阵的元素 $\mathbf{H}_{m,n}^{\text{aug}}$ 可以通过以下规则在角度-延迟域中生成：

$$|\mathbf{H}_{m,n}^{\text{aug}}| = \begin{cases} |\mathbf{H}_{m+i, (n+j) \bmod N_b}|, & 1 \leq m+i \leq R_d, \\ 0 & \text{else,} \end{cases} \quad (2-20)$$

本研究通过将延迟域中 $R_d$ 行之外的元素设置为零来进行矩阵截断。

接下来进一步研究增强相位矩阵。增强的相位应该覆盖超出测量CSI的情况，以增强训练后模型的精度并避免过拟合。考虑到到达天线阵列的路径（包括直接或反射路径）在相同多径延迟下可以共享频率无关的相位偏移[30]，本研究选择均匀分布作为增强相位偏移分布 $\Psi_{\text{aug}}(\cdot) \sim U(0, 2\pi)$ ，应用于CSI相位矩阵的同一行（即相同延迟）的元素。换句话说，本研究构造一个比测量的CSI相位变化更大的相位变化，并使用召回来替换一些精度，以增强实际部署中的CSI恢复精度。因此，对于采样CSI矩阵的每一行，本研究应用一个随机相位移动：

$$\angle \mathbf{H}_{m,n}^{\text{aug}} = \angle \mathbf{H}_{m,n} + \angle e^{-j\theta_m}, \forall m \in [R_d], n \in [N_b], \quad (2-21)$$

其中， $\theta_m \sim \mathcal{U}(0, 2\pi)$ 。

最后，本研究将增强的幅度和相位矩阵组合，生成CSI样本以训练深度反馈模型。

## 2.7 仿真结果与性能分析

### 2.7.1 参数设定

为了进行性能评估，本研究使用以下四个数据集，其中前两个数据集设置通常用于评估CSI估计和反馈技术的性能[4]，第三个数据集来自实际测量，最后一个数据集遵循3GPP标准模型生成：

- 1) Cost2100 室内（Cost2100 Indoor）。该数据集基于COST2100模型[31]生成的，考虑一个位于 $20\text{m} \times 20\text{m}$ 覆盖区域中心的gNB，使用5.3 GHz下行频率。带宽为20 MHz。本研究考虑在gNB处使用 $N_b = 32$ 个天线和 $N_f = 1024$ 个子载波为在覆盖区域内随机分布的单天线UE提供服务。
- 2) Cost2100 室外（Cost2100 Outdoor）。该数据集同样基于COST2100模型生成，考虑一个位于 $400\text{m} \times 400\text{m}$ 覆盖区域中心的gNB，使用300 MHz下行频率。带宽、天线和子载波与Cost2100室内相同。
- 3) 室内实测（Measured Indoor）。该数据集包含从KU Leuven大规模MIMO测试平台记录的 $9\text{ m}^2$ 室内区域的CSI样本[32]。gNB配备有64个天线的均匀线性阵列（ULA）。本研究选择64个天线中的中间32个。对于20 MHz带宽上以2.61 GHz频率间隔为100个子载波采集CSI。
- 4) Quadriga 3GPP UMA。本研究使用QuaDRiGa平台[33]中描述的信道设置生成一个数据集。本研究选择2.6 GHz载波下的城市宏蜂窝（UMa）场景。本研究在20 MHz带宽上考虑具有 $N_b = 32$ 个天线和 $N_f = 1024$ 个子载波的gNB。gNB位于一个边长为400m的正方形区域的中心，为在覆盖区域内随机分布的单天线UE提供服务。将CSI矩阵转换为角延迟域后，由于这四种类型的信道数据都具有稀疏性，只保留前32行。总训练集大小为100,000，测试集大小为20,000，批量大小为64。本研究对SPTM2-ISTANet+使用200个epochs，对CSI-TransNet中的翻译模块和重新翻译模块由于参数较少使用80个epochs。

为了比较不同网络的恢复精度，本研究采用归一化的MSE作为度量，即

$$\text{NMSE} = \frac{1}{N_k} \sum_{k=1}^{N_k} \left\| \mathbf{H}_k - \hat{\mathbf{H}}_k \right\|^2 / \left\| \mathbf{H}_k \right\|^2$$

其中  $\hat{\mathbf{H}}$  是基于反馈恢复的  $\mathbf{H}$ ， $k$  和  $N_k$  分别是测试集中

的样本序号和样本数量。

### 2.7.2 锚模型的反馈精度对比

本研究将 SPTM2-ISTANet+ 与以下三个在大规模 MIMO 系统 CSI 反馈方面表现出优异性能的反馈方案进行对比：

- 1) CsiNet+[6]: 采用较大卷积核( $7 \times 7$ ) 的 CSI 反馈模型，并优化残差单元的结构。
- 2) DCRNet[7]: 增强后的 CRNet [5]，结合多分辨率卷积核和扩张卷积来提取不同粒度的 CSI 特征，并通过预热过程来优化学习率调整。
- 3) ISTANet+: 一种受压缩图像处理[22]启发的 CSI 反馈设计，在[13] 中采用正交随机高斯测量矩阵  $\Phi \in R^{M \times N}$ ，其中  $N = 2048$ ， $M$  取决于压缩率 (Compression Ratio, CR)。

此外，本研究还对比了另一种方法 TM2-ISTANet+，即没有球面处理的 SPTM2-ISTANet+，以展示 SPTM2-ISTANet+ 中不同组成部分的优势。

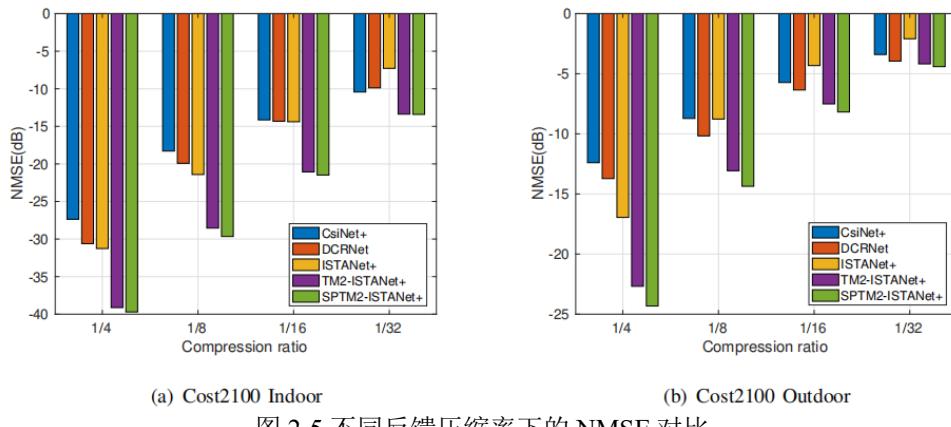


图 2-5 不同反馈压缩率下的 NMSE 对比

上图展示了在使用 Cost2100 模型的室内和室外场景中，五种方案 CsiNet+、DCRNet、ISTANet+、TM2-ISTANet+ 和 SPTM2-ISTANet+ 在不同压缩率下的 CSI 性能比较。迭代块的数量设置为 9。如图 2-5 所示，本研究提出的 SPTM2-ISTANet+ 在所有测试的 CR 下都可以实现更精确的反馈性能。特别是，在具有挑战性的室外场景中的 CR 为 1/4 时，与传统的基于深度学习的方案 DCRNet 和 CsiNet+ 相比，SPTM2-

ISTANet+ 的 CSI 重建精度提高了约 10dB。另一方面，本研究注意到，对于较大的 CR（例如 1/4），ISTANet+ 的性能优于 CsiNet+ 和 DCRNet。在较高压缩（即较小的 CR）下，例如 1/32，ISTANet+ 的性能不如 CsiNet+ 和 DCRNet。本研究的测试结果表明，传统 CS 方法中的随机测量矩阵  $\Phi$  不能有效地提取较小 CR 值的关键数据特征，而基于数据驱动测量矩阵的 TM2-ISTANet+ 则表现更好。

### 2.7.3 数据增强性能对比

基于深度学习的 CSI 反馈工作已经在室内场景中取得了令人满意的性能[5]-[8]，本研究将重点关注室外场景，因为在这种场景下实际 CSI 测量更加困难且 CSI 恢复的准确性较低。对于数据增强，将从 Cost2100 Outdoor 训练集中的有限测量样本中随机选择。本研究将角度域和延迟域的偏移范围分别设置为 -15 到 15 和 -3 到 3。如果初始增强不够大（取决于相应的增强方法），本研究将通过重复或相位随机化将增强后的训练数据集大小设置为与整个训练集大小相同。

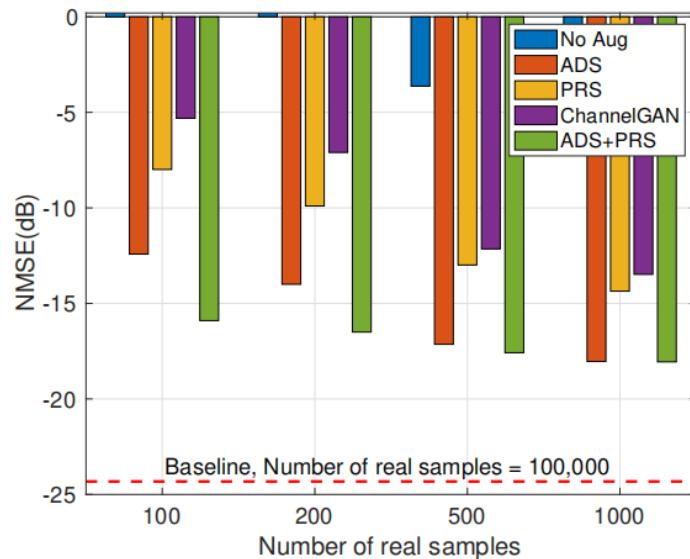


图 2-6 CR = 1/4 时的数据增强性能对比

图 2-6 比较了使用不同增强策略的 SPTM2-ISTANet+ 的性能，包括对抗生成网络方法 ChannelGAN[17]，不进行增强（No Augmentation, No Aug）的方法（通过重复来扩大数据集大小），角度-延迟域的偏移（Shift in Angular-Delay Domain, ADS），随机相位偏移（Phase Random Shift, PRS），以及 ADS 和 PRS 结合（ADS+PRS）。本研究将 CR 设置为 1/4，并将增强前的 CSI 样本数量限制为 100、200、500 和 1000。图 2-5 所示，本研究提出的 ADS 和 ADS+PRS 在每种情况下都明显优于 ChannelGAN。实际

上，仅 PRS 就已经优于 ChannelGAN。

值得注意的是，ADS+PRS 仅使用 100 个 CSI 测量样本就可以实现 NMSE 为  $-15.8$  dB，而 ChannelGAN 只能达到  $-5.3$  dB。此外，ADS 和 PRS 都能提高 CSI 恢复精度。总体而言，由于基于领域知识更好地利用了地理相关性，所提出的使用 ADS 的低成本训练增强始终比 PRS 获得更高的收益。

#### 2.7.4 针对新场景的 CSI 反馈性能对比

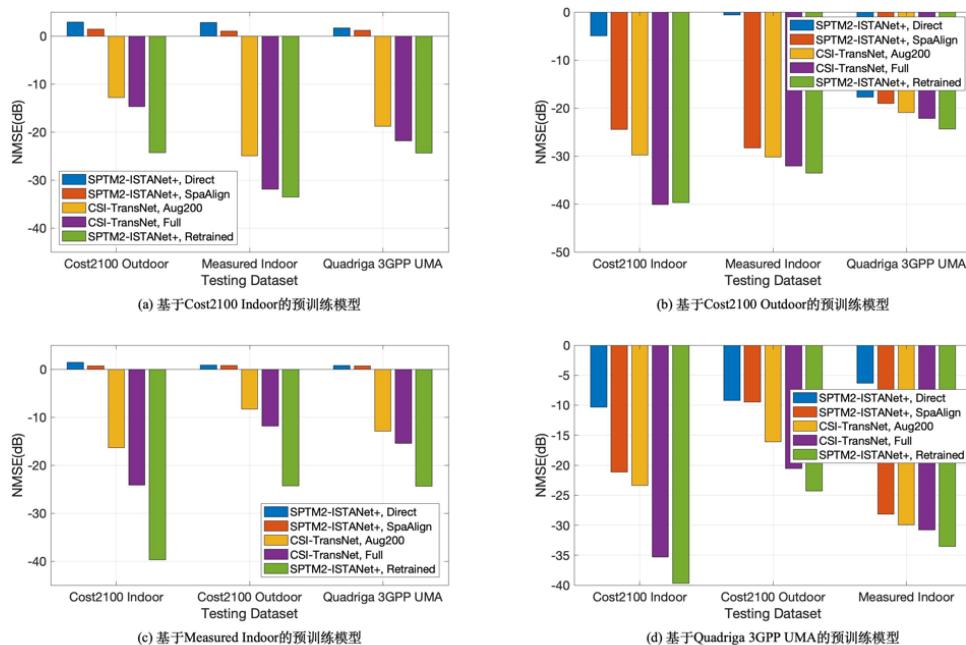


图 2-7 当 CR = 1/4 时预训练模型在新场景的 CSI 反馈性能比较

为了评估 UE 在遇到新场景时的恢复性能，本研究分别选择在 Cost2100 Indoor、Cost2100 Outdoor、Measured Indoor 和 Quadriga 3GPP UMA 中预训练的模型。对于每个模型，本研究使用预训练模型未见过的另外三个数据集作为新场景。

图 2-7展示了在 CR = 1/4 时，在一个场景中预训练的模型在新场景中的 CSI 反馈性能。“SPTM2-ISTANet+, Direct”表示在新场景中不经过任何处理直接使用预训练过的 SPTM2-ISTANet+ 的性能，“SPTM2-ISTANet+, SpaAlign” 表示在稀疏对齐函数  $f_{sa}(\cdot)$  的帮助下预训练过的 SPTM2-ISTANet+ 的性能，“CSI-TransNet, Aug200”表示在新场景中使用基于 200 个样本的 ADS+PRS 数据增强的 CSI-TransNet 的性能。作为基线，“CSI-TransNet, Full”对应于在新场景中使用完整训练集进行训练的 CSI-TransNet，“SPTM2-ISTANet+, Retrained”对应于在新场景中从头重新训练的 SPTM2-ISTANet+ 的性能。如

图 2-7 所示，“SPTM2-ISTANet+, Direct”通常在 CSI 恢复精度方面表现不佳，这与常识一致，即基于深度学习的 CSI 反馈处理泛化性场景的能力有限。在稀疏对齐的帮助下，在 Cost2100 Outdoor 和 Quadriga 3GPP UMA 上预训练的模型在新场景中表现出明显的反馈精度提升，而在 Cost2100 Indoor 和 Measured Indoor 上预训练的模型则没有。实际上，与 Cost2100 Indoor 和 Measured Indoor 相比，Cost2100 Outdoor 和 Quadriga 3GPP UMA 中的 CSI 在多径延迟和到达/离去角度分布方面表现出更多样化的特征，意味着在更多样化的环境中预训练的模型能够更好应对其他信道场景。

在有限的测量数据下，“CSI-TransNet, Aug200”对于每个场景都表现出明显的性能改进，尤其是对于在 Cost2100 Indoor 和 Measured Indoor 上预训练的锚模型。这一观察证实了所提出的可插拔翻译模块和基于模型的信道数据增强的有效性。“CSI-TransNet, Full”在“CSI-TransNet, Aug200”之上提供了额外的收益，这意味着更准确的 CSI-to-CSI 转换可以从预训练模型中获益更多。“SPTM2-ISTANet+, Retrained”作为 CSI 反馈精度的性能上界提供参考。可以观察到，在 Cost2100 Outdoor 和 Quadriga 3GPP UMA 上预训练的模型与重新训练边界之间的差距较小。因此，建议使用在更多样化和复杂环境（如室外）中预训练的模型作为 CSI-TransNet 中的锚网络。

进一步对比不同 CR 下的 CSI 恢复精度。图 2-8 展示了在新场景下在 Cost2100 Outdoor 数据集上的预训练模型的性能。可以观察到“CSI-TransNet, Full”总是具有与“SPTM2-ISTANet+, Retrained”类似的 CSI 恢复性能，这表明所提出的可插拔式的 CSI-to-CSI 转换设计能够有效地重用预训练模型和权重。“CSI-TransNet, Aug200”在  $CR = 1/4$  时达到低于  $-20$  dB 的 NMSE 精度，在  $CR = 1/16$  时达到低于  $-9$  dB 的精度，这说明了在多样化环境中预训练的锚网络有利于场景自适应设计。值得注意的是 Cost2100 Indoor、Measured Indoor 和 Quadriga 3GPP UMA 的载波频率与 Cost2100 Outdoor 的载波频率不同。实际上，Measured Indoor 的子载波间距也与 Cost2100 Outdoor 不同。CSI-TransNet 的性能鲁棒性不受载波频率和子载波间距差异的显著影响，表明所提出的 CSI-TransNet 架构较为灵活，可以在不同场景下重用预训练网络。通过使用来自新环境的少量新测量数据，CSI-TransNet 降低了在多样化和复杂的无线环境中进行实际部署的成本。

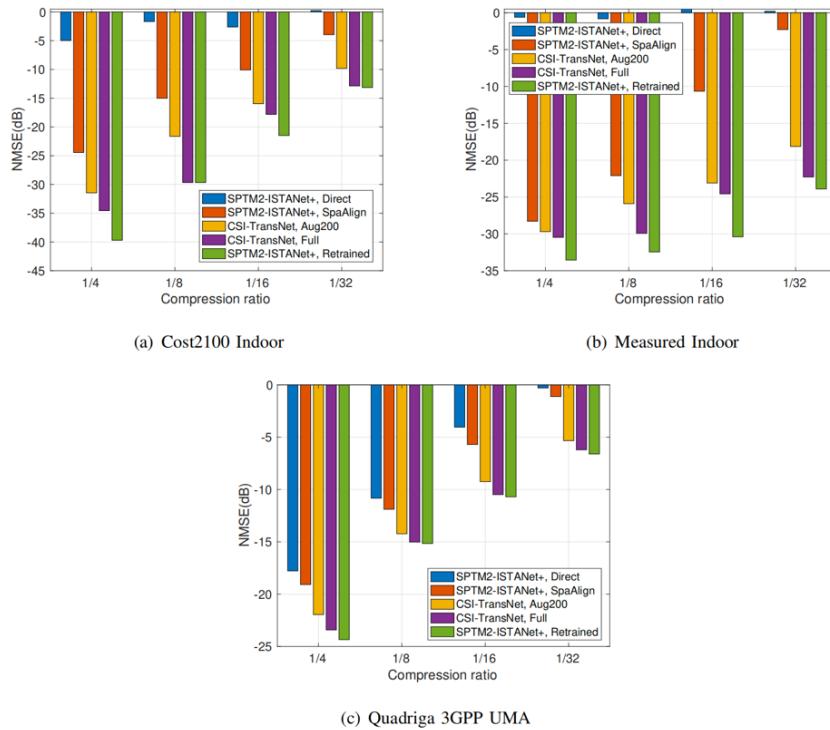


图 2-8 使用 Cost2100 Outdoor 数据集预训练的模型在不同新场景和 CR 下的 CSI 反馈性能比较

## 2.7.5 复杂度对比

本小节针对算法复杂性进行了对比与讨论。表格 2-1 比较了 UE 编码器的参数和 FLOPs。因为资源丰富的 gNB 的计算能力和存储空间较为充足，因此重点关注用户侧。该比较表明，在 CR=1/4 时，与 CsiNet+ 和 DCRNet 相比，SPTM2-ISTANet+ 可以分别减少超过 27% 和 19% UE 计算量，且计算量节省随着 CR 的降低而增加。上述三个编码器的大小（参数数量）处于相似水平。此外，与传统编码器网络相比，所提出的新可插拔翻译模块可以将需要在新场景中更新的 UE 参数数量从 100 万降低到 1800。尽管翻译模块在 CR=1/4 时的 FLOPs 是传统方法的 2 倍，但可以通过利用轻量级优化原理[34] 进一步降低计算复杂性，例如使用卷积优化设计[35] 和知识蒸馏[36]。

表格 2-1 UE 中编码器网络的模型大小和计算复杂度对比，M：百万，K：千

	Parameters				FLOPs			
	CsiNet+	DCRNet	SPTM2-ISTANet+	TransModule	CsiNet+	DCRNet	SPTM2-ISTANet+	TransModule
CR=1/4	1.1 M	1.0 M	1.0 M	1.8 K	2.9 M	2.6 M	2.1 M	3.7 M
CR=1/8	0.5 M	0.5 M	0.5 M	1.8 K	1.9 M	1.6 M	1.0 M	3.7 M
CR=1/16	0.3 M	0.3 M	0.3 M	1.8 K	1.3 M	1.0 M	0.5 M	3.7 M
CR=1/32	0.1 M	0.1 M	0.1 M	1.8 K	1.1 M	0.8 M	0.3 M	3.7 M

表格 2-2 不同数据增强策略的参数和计算复杂度对比, B: 十亿, M: 百万, K: 千

	ChannelGAN	ADS	PRS	ADS+PRS
Parameters	11.7 M	0.2 K	1 K	1 K
FLOPs	5.4 B	-	4.1 K	4.1 K

表格 2-2 比较了不同信道数据增强策略的参数和 FLOPs。与需要数百万参数和数十亿 FLOPs 的 ChannelGAN 不同, 本研究提出的 ADS+PRS 只需要几千个参数和 FLOPs 就可以实现更高的 CSI 恢复精度。

## 2.8 小结

为了节约应急现场的通信带宽占用, 本研究利用时域信道相关性, 为下行 CSI 压缩反馈设计了一种基于模型驱动的高效反馈框架 MarkovNet。应急现场常面临无线信道环境复杂多变的情况, 使得基于深度学习反馈框架的两个主要挑战: 未经历过的全新信道环境和来自现场测量的少量信道样本, 但是使得预训练的信道反馈模型在新环境中性能大幅下降。本研究为基于深度学习的低开销CSI 反馈中的模型训练和部署优化提供了一种新颖的解决方案。对于全新的信道环境, 本研究提出了一种高效的场景自适应 CSI 反馈架构“CSI-TransNet”。CSI-TransNet 利用可插拔 CSI 到 CSI 翻译模块重用具有高恢复精度的预训练锚 CSI 模型, 并在新场景中启用轻量级编码器更新。本研究还设计了一种高效的深度展开式 CSI 反馈网络 SPTM2-ISTANet+ 作为 CSI-TransNet 的骨干网络。针对小样本测量数据集, 本研究提出了一种基于领域知识的简单有效的数据增强策略, 以替代基于 GAN 的高复杂度数据增强。本研究提出的信道数据增强策略与 CSI-TransNet 一起可以显著提高 CSI 恢复性能, 在 CR 为 1/4 的三个新场景中仅需要 200 个测量信道样本即可实现 NMSE 低于 -20 dB, 并且仅需更新一千个编码器参数。

## 参考文献

- [1] Makki B, Eriksson T. On hybrid ARQ and quantized CSI feedback schemes in quasi-static fading channels[J]. IEEE Transactions on Communications, 2012, 60(4): 986-997
- [2] Gao Z, Dai L, Wang Z, et al. Spatially common sparsity based adaptive channel estimation and feedback for FDD massive MIMO[J]. IEEE Transactions on Signal Processing, 2015, 63(23): 6169-6183.
- [3] Son H, Cho Y. Analysis of compressed CSI feedback in MISO systems[J]. IEEE Wireless Communications Letters, 2019, 8(6): 1671-1674.
- [4] Wen C, Shih W, Jin S. Deep Learning for Massive MIMO CSI Feedback[J]. IEEE Wireless Communications Letters, 2018, 7(5): 748-751.
- [5] Lu Z, Wang J, Song J. Multi-resolution CSI feedback with deep learning in massive MIMO system[C]// ICC 2020-2020 IEEE International Conference on Communications. IEEE, 2020: 1-6.
- [6] Guo J, Wen C, Jin S, et al. Convolutional neural network-based multiple-rate compressive sensing for massive MIMO CSI feedback: design, simulation, and analysis[J]. IEEE Transactions on Wireless Communications, 2020, 19(4): 2827-2840.
- [7] Tang S, Xia J, Fan L, et al. Dilated convolution based CSI feedback compression for massive MIMO systems[J]. IEEE Transactions on Vehicular Technology, 2022: 1-6.
- [8] Chen X, Deng C, Zhou B, et al. High-accuracy CSI feedback with super-resolution network for massive MIMO systems[J]. IEEE Wireless Communications Letters, 2022, 11(1): 141-145.
- [9] Lin Y-C, Liu Z, Lee T-S, et al. Deep learning phase compression for MIMO CSI feedback by exploiting FDD channel reciprocity[J]. IEEE Wireless Communications Letters, 2021, 10(10): 2200-2204.
- [10] Guo J, Wen C-K, Jin S. CANet: Uplink-aided downlink channel acquisition in FDD massive MIMO using deep learning[J]. IEEE Transactions on Communications, 2022, 70(1): 199-214.
- [11] Wang T, Wen C, Jin S, et al. Deep Learning-Based CSI Feedback Approach for Time-Varying Massive MIMO Channels[J]. IEEE Wireless Communications Letters, 2019, 8(2): 416-419.

- [12] Liu Z, del Rosario M, Ding Z. A Markovian model-driven deep learning framework for massive MIMO CSI feedback[J]. IEEE Transactions on Wireless Communications, 2022, 21(2): 1214-1228.
- [13] Del Rosario M, Ding Z. Learning-based MIMO channel estimation under practical pilot sparsity and feedback compression[J]. IEEE Transactions on Wireless Communications, 2022: 1-1.
- [14] Shorten C, Khoshgoftaar TM. A survey on image data augmentation for deep learning[J]. Journal of Big Data, 2019, 6(1): 1-48.
- [15] Yang Y, Li Y, Zhang W, et al. Generative-adversarial-network-based wireless channel modeling: Challenges and opportunities[J]. IEEE Communications Magazine, 2019, 57(3): 22-27.
- [16] Ye H, Liang L, Li G Y, et al. Deep learning-based end-to-end wireless communication systems with conditional GANs as unknown channels[J]. IEEE Transactions on Wireless Communications, 2020, 19(5): 3133-3143.
- [17] Xiao H, Tian W, Liu W, et al. ChannelGAN: Deep learning based channel modeling and generating[J]. IEEE Wireless Communications Letters, 2022, 11(3): 650-654.
- [18] Yang Y, Gao F, Zhong Z, et al. Deep transfer learning-based downlink channel prediction for FDD massive MIMO systems[J]. IEEE Transactions on Communications, 2020, 68(12): 7485-7497.
- [19] Zeng J, Sun J, Gui G, et al. Downlink CSI feedback algorithm with deep transfer learning for FDD massive MIMO systems[J]. IEEE Transactions on Cognitive Communications and Networking, 2021, 7(4): 1253-1265.
- [20] Li X, Guo J, Wen C-K, et al. Multi-task learning-based CSI feedback design in multiple scenarios[J]. arXiv preprint arXiv:2204.12698, 2022.
- [21] Lu Z, Wang J, Song J. Multi-resolution CSI Feedback with Deep Learning in Massive MIMO System[C]//ICC 2020 - 2020 IEEE International Conference on Communications (ICC). IEEE, 2020: 1-6.
- [22] Zhang J, Ghanem B. ISTA-Net: Interpretable optimization-inspired deep network for image compressive sensing[C]//2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2018: 1828-1837.
- [23] Beck A, Teboulle M. A fast iterative shrinkage-thresholding algorithm for linear inverse problems[J]. SIAM Journal on Imaging Sciences, 2009, 2(1): 183-202.
- [24] Wang C, Xu C, Wang C, et al. Perceptual adversarial networks for image-to-image transformation[J]. IEEE Transactions on Image Processing, 2018, 27(8): 4066-4079.

- [25] Park T, Efros A A, Zhang R, et al. Contrastive learning for unpaired image-to-image translation[C]//ECCV 2020. Springer International Publishing, 2020: 319-345.
- [26] Badrinarayanan V, Kendall A, Cipolla R. SegNet: A deep convolutional encoder-decoder architecture for image segmentation[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, 39(12): 2481-2495.
- [27] Wang C. Kernel learning for visual perception, chapter 2.2[D]. Nanyang Technological University, 2019.
- [28] Dumoulin V, Visin F. A guide to convolution arithmetic for deep learning[J]. 2016. arXiv preprint arXiv:1603.07285.
- [29] Hejazi F, Vuckovic K, Rahnavard N. DyLoc: Dynamic localization for massive MIMO using predictive recurrent neural networks[C]//INFOCOM 2021 - 2021 IEEE International Conference on Computer Communications (INFOCOM). IEEE, 2021: 1-9.
- [30] Tse D, Viswanath P. Fundamentals of wireless communication[M]. Cambridge university press, 2005.
- [31] Liu L, Oestges C, Poutanen J, et al. The COST 2100 MIMO channel model[J]. IEEE Wireless Communications, 2012, 19(6): 92-99.
- [32] De Bast S, Pollin S. Ultra dense indoor MaMIMO CSI dataset. IEEE Dataport. 2021. [Online]. Available: <https://dx.doi.org/10.21227/nr6k-8r78>
- [33] Jaeckel S, Raschkowski L, Börner K, Thiele L. Quadriga: A 3-D multi-cell channel model with time evolution for enabling virtual field trials[J]. IEEE Transactions on Antennas and Propagation, 2014, 62(6): 3242-3256.
- [34] Guo J, Wang J, Wen C-K, Jin S, Li GY. Compression and acceleration of neural networks for communications[J]. IEEE Wireless Communications, 2020, 27(4): 110-117.
- [35] Cao Z, Shih W-T, Guo J, Wen C-K, Jin S. Lightweight convolutional neural networks for CSI feedback in massive MIMO[J]. IEEE Communications Letters, 2021, 25(8): 2624-2628.
- [36] Lu Z, Zhang X, Zeng R, Wang J. Better lightweight network for free: Codeword mimic learning for massive MIMO CSI feedback[J]. arXiv preprint arXiv:2210.16544, 2022. [Online]. Available: <https://arxiv.org/abs/2210.16544>

# 3 面向移动应急场景的动态通导网络适配

## 3.1 引言

在自然灾害处置、事故灾难救援等突发公共事件中，救援人员面临着移动通信基础设施缺失/损毁、卫星导航信号断续不稳等恶劣环境，亟需加强现场应急指挥能力建设，保障通信和定位等关键业务需求。在党的二十大报告中指出，要完善国家应急管理体系，提高防灾减灾救灾和急难险重突发公共事件处置保障能力。大量情况下，受灾区域的用户在灾害发生初期无法外部通信，难以支撑应急行动辅助决策需求，导致应急精准响应能力下降，需要快速调度应急救援力量搭建应急基站实现通信恢复、快速补盲等功能，以提升应急通信覆盖、提高定位精度并增强应急救援的业务保障能力。“十四五”规划和 2035 年远景目标纲中指出“加强极端条件应急救援通信能力建设”，建立灵活机动、通导融合的应急网络是应急管理的关键环节，是支持灾害响应和救援的重要部分。

无人机网络通过其搭载的便携基站等设备，可以在没有现有基础设施的情况下快速部署应急网络，为救援力量和受灾人员提供通信、定位等服务，从而增强应急区域的救援处置能力。目前，无人机的网络部署和路径方案已经成为研究的重点。文献[1]利用图填充理论优化无人机的部署位置，通过调整无人机的高度和天线波束宽度，以降低无人机的部署数量和成本，同时保证目标区域的覆盖率。文献[2]提出了能量高效的三维无人机基站部署方案，通过在垂直和水平维度进行解耦，最小化无人机的发射功率，同时最大化无人机基站所覆盖的用户数量。文献[3]-[5]研究了面向高能效与高时效感知数据采集等目标的无人机路径规划方案。文献[6]以最大化多层次服务质量为目标提出一种新颖的惯性权重更新方法以优化无人机的位置。文献[7]和[8]基于遗传算法提出了面向通信覆盖优化的无人机网络部署方案。

在实际应急场景中，应急业务需要通信与定位服务的共同支持。例如在救援队伍的派出过程中，每架无人机不仅需要提供通信网络的覆盖，保障救援相关信息的上传与下达，同时无人机需要面向救援力量提供定位服务，为精准救援与高效撤离提供导航参考。由于应急场景环境复杂、变化动态，不确定因素较多，如何高效调度有限的

应急基站满足应急业务需求十分关键，然而现有研究工作[1]-[9]通常偏向提供单一功能的应急服务，并且均未考虑如何规避山体等障碍物导致的非视距链路以提升应急服务质量。

同时，应急现场中目标区域的通信与定位需求会因为地面用户的移动、救援任务的演进等因素随着时间发生较大地动态改变，静态的部署方案很难为目标区域持续地提供可靠的通导服务，因此需要根据地面用户的位置和需求变化对基站的部署位置进行动态适配。然后，由于无人机的续航能力受到其装载的电池容量限制，能量耗尽而退出服务的无人机将极大影响网络的稳定性和应急服务质量。尽管当前已有部分工作研究了无人机能耗模型并制定了相应的节能和低能耗部署策略[9][22]，但仍未缺乏对通导一体化部署中能耗最小化问题的深入研究。现有基于启发式算法的无人机调度方案[6][10]由于需要使用大量的随机种子与迭代提升网络覆盖性能，通常面临计算复杂度较高和方案输出缓慢的问题，难以实时输出部署结果和提供快速按需覆盖，无法满足应急场景的高效调度和稳定覆盖要求。因此，如何面向通导融合的动态部署需求，设计低复杂度的动态应急网络适配方案以实现应急无人机网络低能耗部署仍待深入研究。

因此，针对应急现场人员移动引发的通信网络覆盖率与定位精度下降，本研究聚焦无人机辅助的动态应急网络调整，提出了基于虚拟力模型的应急通导网络动态适配方案，保障移动场景下应急网络的稳定覆盖。具体而言，为了提升无人机基站在有限续航能量下的应急网络通导服务质量，本研究首先设计了通导能量效用指标，并以通导能量效用最大化为优化目标建模了应急通导网络优化部署问题；然后，为了在保障移动应急场景下通导需求的同时实现网络适配方案的高效快速输出，本研究设计了基于通信需求与定位需求的虚拟引力建模方案；在此基础上，为了规避山地等障碍物遮挡导致的强衰落非视距链路，本研究提出了非视距链路规避引力建模方案；进一步地，为了避免无人机与障碍物以及无人机之间发生碰撞进行了虚拟斥力建模，然后基于无人机所受合力方向与大小进行无人机部署位置优化。其中，针对无人机能量受限带来的网络节点失能和通导服务质量下降问题，本研究设计了无人机能量自适应的移动步长适配方案，在保障应急网络高效覆盖的前提下有效提升无人机节点的工作时间和通导能量效用，并支持秒级的动态位置调整方案快速输出。

## 3.2 系统模型

通导一体化场景需部署无人机实现对地面用户的通导服务支持。定义用户集合为  $U = \{1, 2, \dots, u, \dots, |U|\}$ 。假设所有用户位于水平面，需要应急网络提供通信与定位服务。定义用户  $u$  的坐标为  $\mathbf{u}_u = [x_u, y_u, 0]$ 。定义无人机集合为  $M = \{1, \dots, m, \dots, |M|\}$ 。定义无人机  $m$  的坐标为  $\mathbf{s}_m = [x_m, y_m, z_m]$ 。每架无人机可以在自身能力范围内提供通导服务。

对于应急通信覆盖，假定当无人机  $m$  为用户  $u$  间信噪比满足  $\gamma_{u,m} \geq \gamma_u^h$  时，则可为用户  $u$  提供通信服务。同时，定义二元变量  $\alpha_{m,u}$  表示无人机  $m$  是否为用户  $u$  提供通信服务，即

$$\alpha_{m,u} = \begin{cases} 1, & \text{若无人机 } m \text{ 为用户 } u \text{ 提供通信服务,} \\ 0, & \text{其他。} \end{cases} \quad (3-1)$$

对于应急定位，假定无人机间可通过卫星定位系统获得精确位置信息并进行时间同步校准。定义支撑地面用户达到目标定位精度所需的最小定位无人机数量为  $L$ ，其中对于定位地面节点的二维坐标，至少需要三架无人机进行协同定位。定义二元变量  $\beta_{m,u}$  表示无人机  $m$  是否为用户  $u$  提供定位服务，即

$$\beta_{m,u} = \begin{cases} 1, & \text{若无人机 } m \text{ 为用户 } u \text{ 提供定位服务,} \\ 0, & \text{其他。} \end{cases} \quad (3-2)$$

接下来，定义包含所有  $L$  架无人机的集合为  $K = \{C_1, \dots, C_k, \dots, C_K\}$ ，无人机定位子组总数为  $K$ 。 $C_k$  为第  $k$  个无人机子组，表示为  $C_k = \{k_1, \dots, k_l, \dots, k_L\}$ ，其中  $k_i = 1, 2, \dots, |M|$  表示无人机子组内的无人机编号。

为了利用有限的资源实现应急现场用户的高效覆盖，现有方案通常假定在已知用户位置集合  $\{\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_{|U|}\}$  的前提下设计应急网络部署方案。然而，在实际应急部署过程中，地面用户的位置无法理想已知，需要通过定位网络获取存在误差的位置估计  $\{\hat{\mathbf{u}}_1, \hat{\mathbf{u}}_2, \dots, \hat{\mathbf{u}}_{|U|}\}$ 。

### 3.2.1 信道模型

无人机基站与用户之间的信号传输采用林区信道模型中的倾斜信道模型。在倾斜信道模型中，无人机基站与用户之间的总路径损耗由对数距离损耗、阴影衰落和林区

中的额外损耗组成。定义第*i*个无人机与第*j*个用户之间的总路径损耗为 $L_{i,j}$ (dB)，根据ITU-R Recommendation P.833-9有：

$$L_{i,j} = L_{i,j}^{FSPL} + 10\alpha \lg \left( \frac{d_{i,j}}{d_0} \right) + X_\sigma + L_{i,j}^{Slant}, \quad (3-3)$$

其中 $d_0$ 为参考距离， $X_\sigma$ 表征信道中阴影衰落的影响，服从均值为零、标准差为 $\sigma$ 的高斯分布。

$L_{i,j}^{FSPL}$ 表示第*i*个无人机与第*j*个用户之间的自由空间路径损耗，可以表示为

$$L_{i,j}^{FSPL} = 20 \lg \left( \frac{4\pi f d_0}{c} \right), \quad (3-4)$$

其中， $f$ 、 $c$ 分别表示载波频率与光速。

$L_{i,j}^{Slant}$ 表示林区信道模型中的额外损耗，可以表示为：

$$L_{i,j}^{Slant} = A f^B d_{i,j}^C (\theta_{i,j} + E)^G, \quad (3-5)$$

其中， $A$ 、 $B$ 、 $C$ 、 $E$ 与 $G$ 为环境参数， $\theta_{i,j}$ 是第*i*个无人机与第*j*个用户之间与地平面的夹角。

考虑到无人机和无人机之间通常在空中的开放空间进行通信，它们之间的信道主要由视距链路决定。因此，无人机之间的路径损耗使用自由空间路径损耗来建模[11]，即使用公式(4-4)。

当无人机与地面用户之间被山体遮挡时，对于微波频段的近距离跨山通信，散射传播损耗将显著增加使得接收信号可以忽略不记[12]。因此，本研究假定无人机和用户无法在山体遮挡的情况下进行通信，需要在完成非视距规避之后才能恢复通信。

### 3.2.2 定位模型

本研究采用以无人机基站为锚点的 TDOA 定位，并选取克拉美罗界（Cramer-Rao Lower Bound, CRLB）的迹作为评价定位基站在不同几何构型时定位性能优劣的度量[13]。假定服务于位置  $\mathbf{p}=[p_x, p_y, p_z]$  用户的定位无人机子组为第  $k$  个子组  $C_k = \{k_1, \dots, k_l, \dots, k_L\}$ ，其中  $k_i = 1, 2, \dots, |M|$ 。用户到第  $k_i$  个无人机基站与第  $k_1$  个无人机基站的 TDOA 测量模型可以表示为  $d_{k_i, k_1} = d_{k_i} - d_{k_1} + n_{k_i, k_1}$ ，其中  $d_{k_i} = \|\mathbf{s}_{k_i} - \mathbf{p}\|$  为第  $k$  架无人机与用户的距离， $n_{k_i, k_1}$  为噪声导致的距离误差。

基于上述模型，克拉美罗界的迹可以表示为  $J = \text{tr}(CRLB) = \text{tr}(\mathbf{F}^{-1})$ ，其中  $\mathbf{F}^{-1} = (\mathbf{Q}^T \mathbf{R}^{-1} \mathbf{Q})^{-1}$ ， $\mathbf{R} = \text{cov}(\mathbf{e} \cdot \mathbf{e}^T)$  为测距误差的协方差矩阵， $\mathbf{Q}$  为包含无人机基站及目标位置的矩阵，表示为：

$$\mathbf{Q} = \begin{bmatrix} \frac{(\mathbf{p} - \mathbf{s}_{k_2})}{\|\mathbf{p} - \mathbf{s}_{k_2}\|} - \frac{(\mathbf{p} - \mathbf{s}_{k_1})}{\|\mathbf{p} - \mathbf{s}_{k_1}\|} \\ \frac{(\mathbf{p} - \mathbf{s}_{k_3})}{\|\mathbf{p} - \mathbf{s}_{k_3}\|} - \frac{(\mathbf{p} - \mathbf{s}_{k_1})}{\|\mathbf{p} - \mathbf{s}_{k_1}\|} \\ \vdots \\ \frac{(\mathbf{p} - \mathbf{s}_{k_L})}{\|\mathbf{p} - \mathbf{s}_{k_L}\|} - \frac{(\mathbf{p} - \mathbf{s}_{k_1})}{\|\mathbf{p} - \mathbf{s}_{k_1}\|} \end{bmatrix} \quad (3-6)$$

定义位于  $\mathbf{u}_u$  的用户  $u$  的克拉美罗界的迹为  $J_u$ ，本研究使用所有用户的平均克拉美罗界的迹  $J_{mean} = \frac{1}{|\mathcal{U}|} \sum_{u=1}^{|\mathcal{U}|} J_u$  评价定位网络部署算法的整体性能。

### 3.2.3 无人机能耗模型

无人机的能量消耗主要包括三部分：(1) 支持无人机飞行到部署位置的推动力量 (propulsion energy)，(2) 支持内容传输的通信能量以及 (3) 执行任务时的悬停能量。由于无人机在执行任务过程中所产生的通信与定位信号传输能耗与飞行能耗相比可以忽略不计，因此本研究重点关注无人机的飞行能耗。

具有速度  $V$  的旋翼无人机的移动能量可以表示为[15]：

$$E^P = P_0 \left( 1 + \frac{3V^3}{U^2} \right) + P_1 \left( \left( 1 + \frac{V^4}{4v_r^4} \right)^{\frac{1}{2}} - \frac{V^2}{2v_r^2} \right)^{\frac{1}{2}} + \frac{1}{2} AV^3 \quad (3-7)$$

其中， $P_0, P_1, U, v_r$  以及  $A$  是与无人机重量、机翼面积、空气密度等相关的常数参数。

此外，当无人机的速度为 0，上式即表示无人机的悬停功耗。因此结合  $E^P$  表达式，代入  $V = 0$ ，无人机的悬停能耗可以表示为：

$$E^H = P_0 + P_1 \quad (3-8)$$

### 3.3 问题建模

保障灾害现场应急网络的稳定拓扑结构是应急现场指挥需要考虑的重要因素之一。由于无人机的有限续航，不合理的飞行调度将导致部分无人机提前耗尽能量而退出网络，致使整个拓扑需要重新调整，同时也将加快剩余无人机的能量消耗。因此，不同于当前通常面向最大化通信或定位服务质量的无人机网络部署方案，本研究进一步在优化通信和定位服务质量的同时在优化目标中考虑提升整体网络的平均剩余能耗，支持更为长效的通导网络覆盖。

将应急通导网络的调度过程分为 $T$ 个时段，集合表示为 $\mathbf{T} = \{1, \dots, t, \dots, T\}$ 。由于飞行能力限制，无人机 $m$ 在相邻两次部署的移动距离需小于最大值 $d_m^{\max}$ ，即：

$$\|\mathbf{s}_m(t) - \mathbf{s}_m(t-1)\| \leq d_m^{\max}. \quad (3-9)$$

同时，在任意时刻 $t$ ，无人机间的距离需不小于安全距离 $d_r^{\text{th}}$ ，表示为：

$$\|\mathbf{s}_m(t) - \mathbf{s}_n(t)\| \geq d_r^{\text{th}}. \quad (3-10)$$

对于地面用户，假定其在一定范围的受灾区域内进行移动，并使用布朗运动来描述用户的移动轨迹[16]。由于地面用户的移动速度有限，用户 $u$ 在任一时段内移动距离需小于最大值 $l_u^{\max}$ ，即：

$$\|\mathbf{u}_m(t) - \mathbf{u}_m(t-1)\| \leq l_u^{\max}. \quad (3-11)$$

本研究使用所有用户在时段 $t$ 的平均定位性能 $J_{mean}(t) = \frac{1}{|\mathbf{U}|} \sum_{u=1}^{|\mathbf{U}|} J_u(t)$ 表征定位网络的整体性能；使用所有用户在时段 $t$ 的平均可达通信速率 $R_{mean}(t) = \frac{1}{|\mathbf{U}|} \sum_{u=1}^{|\mathbf{U}|} \sum_{m=1}^{|\mathbf{M}|} \alpha_{u,m} R_{u,m}(t)$ 表征通信网络的整体性能，其中 $R_{u,m}(t) = \log_2(1 + \gamma_{u,m})$ ；使用所有无人机在时段 $t$ 的平均能量消耗比例 $E_{mean}^{ratio}(t) = \frac{1}{|\mathbf{M}|} \sum_{m=1}^{|\mathbf{M}|} \frac{E_m^{cost}(t)}{E^{total}}$ 表征网络在时段 $t$ 的能量消耗水平。

为了使相同能耗水平下可以产生的更优通信和定位性能，本研究创新性地提出了单位电池能量比例消耗下的通导效用指标，即通导性能加权差除以相应的能量消耗百分比。由于定位误差越小代表定位性能越好，因此在定位误差项前面使用负号。本研究的目标时以最大化服务时间内单位能量消耗下的通信与定位效用为优化目标，以通导服务需求、飞行安全距离和能耗为约束条件，联合优化无人机部署位置以及无人机与通导用户关联，该通导一体化低能耗部署问题建模为：

$$\mathbf{P}_1 : \max_{\{\mathbf{s}_m(t)\}, \{\alpha_{u,m}(t)\}, \{\beta_{u,m}(t)\}} \sum_{t=1}^T \frac{(R_{mean}(t) - \kappa J_{mean}(t))}{E_{mean}^{ratio}(t)} \quad (3-12)$$

$$s.t. \sum_{m \in M} \alpha_{m,u}(t) \geq 1, \forall u \in U, \forall t \in T, \quad (a)$$

$$\sum_{m \in M} \beta_{m,u}(t) \geq L, \forall u \in U, \forall t \in T, \quad (b)$$

$$0 \leq E_m^{res}(t) \leq E_m^{total}, \forall m \in M, \forall t \in T, \quad (c)$$

$$\|\mathbf{s}_m(t) - \mathbf{s}_m(t-1)\| \leq d_m^{\max}, \forall t \in T, \quad (d)$$

$$\|\mathbf{s}_m(t) - \mathbf{s}_n(t)\| \geq d_r^{\text{th}}, \forall m, n \in M, m \neq n, \forall t \in T, \quad (e)$$

$$\|\mathbf{s}_m(t) - \mathbf{o}_i(t)\| \geq d_o^{\text{th}}, \forall m \in M, \forall i \in O, \forall t \in T, \quad (f)$$

$$\|\mathbf{u}_m(t) - \mathbf{u}_m(t-1)\| \leq l_u^{\max}, \forall u \in U, \forall t \in T, \quad (g)$$

$$x_u(t) \in [-L_x, L_x], y_u(t) \in [-L_y, L_y], \forall u \in U, \forall t \in T, \quad (h)$$

其中， $\kappa$ 用于平衡优化目标中定位性能与通信性能的权重，约束条件(a)表示至少有一架无人机为用户提供通信网络接入，定义  $\text{idx}$  为无人机到用户  $u$  的信噪比集合  $\{\gamma_{1,u}(t), \dots, \gamma_{|M|,u}(t)\}$  中最大值元素的序号，则当  $\gamma_{\text{idx},u}(t) \geq \gamma_u^{\text{th}}$  时， $\alpha_{\text{idx},u}(t) = 1, \forall u \in U$ ；约束条件(b)表示至少有  $L$  架无人机为用户提供定位服务；约束条件(c)限定了无人机的能耗范围，其中  $E_m^{total}$  表示第  $m$  架无人机的总能量；约束条件(d)表示无人机的飞行能量约束，相邻两时刻部署的间隔距离应小于最大值  $d_m^{\max}$ ；约束条件(e)表示任意时刻任意两架无人机的距离需要大于安全距离  $d_r^{\text{th}}$ ，以防发生碰撞；约束条件(f)表示任意时刻无人机与障碍物之间的距离需要大于安全避障距离  $d_o^{\text{th}}$ ；约束条件(g)表征了地面用户有限时间内的移动能力约束；约束条件(h)表征了用户的活动范围。

### 3.4 基于虚拟力模型的通导网络部署

在缺乏用户位置先验信息情况下，难以基于无线信道模型和测距误差模型衡量部署效果的好坏，将限制有限应急资源下的网络覆盖率和服务质量。此时可以通过搭建临时应急定位网络或派出搜寻无人机等方式为应急网络部署提供初始位置参考。本研究首先通过采用文献[10]中面向区域定位精度优化的网络部署，以最大化区域定位精度为目标，得到用户的初始位置估计  $\{\hat{\mathbf{u}}_1, \hat{\mathbf{u}}_2, \dots, \hat{\mathbf{u}}_{|\mathcal{U}|}\}$  并提供给后续通导网络部署算法。

在获得用户位置的初始估计之后，由于问题  $P_1$  仍是非凸非线性优化问题，且需要在优化目标中最大化所有服务时间的无人机平均剩余能耗与用户通导性能加权和的乘

积，使得求解复杂度极高，难以满足应急场景下的快速求解与高效调度需求。因此，本研究将求解全局最优的方案转化为求解局部最优的方案，将通导网络部署的优化目标简化为在给定用户先验定位信息  $\{\hat{\mathbf{u}}_1(t), \hat{\mathbf{u}}_2(t), \dots, \hat{\mathbf{u}}_{|\mathcal{U}|}(t)\}$  的情况下，最大化当下时刻的无人机平均剩余能耗与通导性能加权和，即以应对应急场景下的快速调度方案输出需求。相应的优化问题可以表示为：

$$P_3 : \max_{\{\mathbf{s}_m(t)\}, \{\alpha_{u,m}(t)\}, \{\beta_{u,m}(t)\}} \frac{(R_{mean}(t) + \kappa J_{mean}(t))}{E_{mean}^{ratio}(t)} \quad (3-13)$$

$$s.t. \sum_{m \in M} \alpha_{m,u}(t) \geq 1, \forall u \in U, \quad (a)$$

$$\sum_{m \in M} \beta_{m,u}(t) \geq L, \forall u \in U, \quad (b)$$

$$0 \leq E_m^{res}(t) \leq E_m^{total}, \forall m \in M, \quad (c)$$

$$\|\mathbf{s}_m(t) - \mathbf{s}_m(t-1)\| \leq d_m^{\max}, \quad (d)$$

$$\|\mathbf{s}_m(t) - \mathbf{s}_n(t)\| \geq d_r^{\min}, \forall m, n \in M, m \neq n, \quad (e)$$

$$\|\mathbf{s}_m(t) - \mathbf{o}_i(t)\| \geq d_o^{\min}, \forall m \in M, \forall i \in O \quad (f)$$

$$x_u(t) \in [-L_x, L_x], y_u(t) \in [-L_y, L_y], \forall u \in U, \quad (g)$$

对于上述问题，传统的应急网络部署算法[10] [21]通常采用基于启发式算法的集中式求解方法，这些算法通常需要生成大量随机样本并择优迭代，同时需要通过匹配将前后部署位置进行时间上的移动轨迹关联，在实际应用中通常面临着计算复杂度高和空间连续性差等问题，难以满足应急现场临时无人机网络快速高能效部署的需求。为了实现应急网络的高效部署，本研究设计了基于虚拟力算法的通导网络部署方案。基本思想是通过将通信需求和定位需求建模为虚拟引力，构造目标方位的引力场和障碍物周围的斥力场共同作用的虚拟力场，搜索势函数的下降方向来寻找最优路径，使基站可以沿虚拟斥力和虚拟引力的合力方向动态调整位置，并结合无人机的剩余能耗自适应调整移动步长。

由于待救援区域的用户位置通常是未知的，本研究设计的虚拟力模型首先基于面向区域定位精度最大化的网络部署方案获取地面用户的位置信息。在此基础上，为了实现通导一体化的应急网络覆盖，本研究将每个无人机基站的运动建模为 5 种虚拟力影响的结果：1) 用户对基站的虚拟通信引力，该引力将吸引基站向用户分布更密集的区域靠拢，从而达到负载均衡的目的；2) 基站的非视距链路规避引力，该引力将吸引基站向可以规避非视距链路的位置移动，从而提升无线链路质量；3) 用户对基站的虚

拟定位引力，该引力将吸引定位子组中的基站向定位误差方向减小的方向移动，从而达到提示定位精度的目的；4) 基站之间的虚拟斥力，该斥力可以避免无人机之间的相对距离过近带来碰撞等安全问题，同时能够在运动调整的过程中避免基站的覆盖范围有较大重叠浪费；5) 基站与障碍物之间的虚拟斥力，该斥力可以避免基站与障碍物碰撞。在应急网络适配过程中，无人机基站和背负式基站会受到四种虚拟力的影响自适应调整水平部署位置。

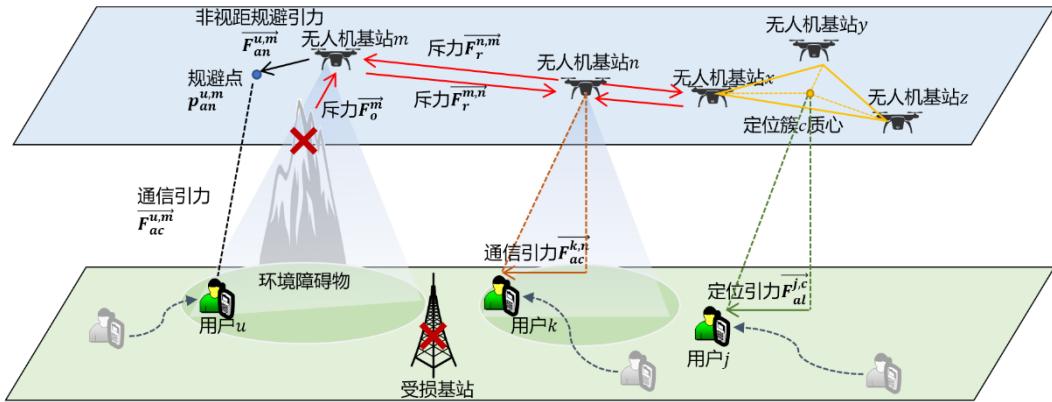


图 3-1 面向动态移动场景基于虚拟力模型的无人机部署

如图 3-1 所示，虚拟通信引力的作用是将无人机牵引向用户设备以保障通信服务质量，该力的设计主要对应于优化目标中的通信速率优化以及通信阈值约束。受库仑力的设计的启发，将通信引力大小建模为与距离的平方成反比，并且方向为从基站位置指向用户位置。具体而言，无人机基站  $m$  受到用户  $k$  的虚拟通信引力表征如下：

$$\overline{\mathbf{F}}_{ac}^{k,m} = \frac{K_a^C \times \max(\gamma_{k,m} - \gamma_k^{th}, 0)}{\|\hat{\mathbf{u}}_k' - \mathbf{s}_m'\|^2}, \quad (3-14)$$

其中  $\gamma_{k,m}$  为无人机  $m$  与用户  $k$  间的信噪比， $\gamma_k^{th}$  为用户  $k$  的可以通信的信噪比阈值， $A_m$  为无人机基站  $m$  服务的用户集合， $K_a^C$  为通信引力系数， $\hat{\mathbf{u}}_k'$  为用户  $k$  定位结果对应的二维平面位置， $\mathbf{s}_n'$  为无人机基站  $n$  对应的二维平面位置。

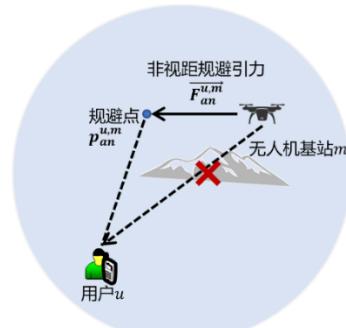


图 3-2 非视距规避引力示意图

当存在山体等严重遮挡时，指向用户方向的引力难以带来信号传输质量的显著提升，此时需要通过规避非视距链路来提升地面用户的服务质量。因此，本研究提出了非视距规避引力。如图 3-2 所示，虚拟非视距规避引力的作用是将无人机牵引至可以向地面用户提供视距链路的位置。结合应急现场的地图信息或者前期的无线环境感知等手段，可以获得能够向所服务的用户集合提供视距链路的位置，因此本研究假定对于非视距联通下的无人机基站  $m$  对于所服务的用户集合可以获取其非视距链路规避点的位置  $\mathbf{p}_{an}^m$ 。由于非视距链路规避的优先级较高，将非视距规避引力大小建模为与非视距规避点到基站的距离成正比，并且方向为从基站位置指向非视距规避点位置。具体而言，无人机基站  $m$  受到所服务用户的虚拟非视距规避引力表征如下：

$$\overrightarrow{\mathbf{F}_{an}^m} = K_a^N \times \|\mathbf{p}_{an}^m - \mathbf{s}'_m\| \times \eta_m, \quad (3-15)$$

其中  $\eta_m$  表征无人机  $m$  与所服务的用户之间是否存在非视距链路， $K_a^N$  为非视距规避引力系数， $\mathbf{p}_{an}^m$  为基站  $m$  的非视距规避点的二维平面位置， $\mathbf{s}'_m$  为无人机基站  $m$  对应的二维平面位置。

算法 4-2 中给出了当无人机基站  $m$  与所服务的用户集合之间存在非视距链路时，当障碍物对可以投影为一条线段时，如何结合无人机的当前位置  $\mathbf{s}'_m$ 、用户位置结合  $\{\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_{|\mathcal{U}_m|}\}$  和障碍物位置求取非视距规避位置。所设计算法的总体思想根据从无人机的当前位置，向经过用户与障碍物端点的直线引出垂线求出垂足位置，并将垂足位置加入潜在位置集合  $F$ ，以尽量降低无人机飞往非视距规避位置的距离。然后，从潜在位置集合  $F$  中筛选出与无人机所服务的用户不存在非视距链路的位置集合  $P$ ，并从中选取所需移动距离最短的点作为非视距规避点。图 3-3 展示了当障碍物两侧都存在用户，且无人机与障碍物右侧的两个用户的链路被阻隔为非视距时，通过算法 4-2 求取的非视距链路规避位置。从图 3-3 可以看到，非视距链路规避位置在保持和原有视距用户链路连接的同时，可以实现与障碍物右侧两个用户的非视距链路规避。

#### 算法 3-2 非视距规避位置求解算法

**输入：**无人机  $m$  的初始位置  $\mathbf{s}'_m$ ，无人机  $m$  服务用户集合的位置  $\{\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_{|\mathcal{U}_m|}\}$ ，

障碍物起点和终点位置  $\{\mathbf{o}_1, \mathbf{o}_2\}$

**输出：**无人机  $m$  的非视距规避位置  $\mathbf{p}_{an}^m$

1: 初始化：

2: 初始化无人机的潜在位置集合  $F$  和可行位置集合  $P$  为空集。

3: 迭代( $i \leq |\mathbf{U}_m|, j \leq 2$ ):

4: 对于 $\{\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_{|\mathbf{U}_m|}\}$ 中的每一个用户位置 $\mathbf{u}_i$ 和障碍物的端点 $\mathbf{o}_j$ , 计算穿过 $\mathbf{u}_i$ 和 $\mathbf{o}_j$ 的直线到无人机最近的点 $\mathbf{p}_{i,j}$ , 并将其放入集合 $F$ 。其中 $\mathbf{p}_{i,j}$ 可以通过点到直线垂足位置的计算公式来求解, 即 $\mathbf{p}_{i,j} = \mathbf{o}_j + \frac{(\mathbf{s}'_m - \mathbf{o}_j) \cdot (\mathbf{u}_i - \mathbf{o}_j)}{\|\mathbf{u}_i - \mathbf{o}_j\|^2} \cdot (\mathbf{u}_i - \mathbf{o}_j)$ 。

5: 对于 $F$  中的每一个位置 $\mathbf{p}_{i,j}$ , 计算穿过 $\mathbf{u}_i$ 和 $\mathbf{p}_{i,j}$ 的直线是否与障碍物 $\{\mathbf{o}_1, \mathbf{o}_2\}$ 相交, 即是否存在非视距路径。如果不存在相交, 则将该位置加入可行位置集合 $P$ 。

#### 6: 迭代结束

7: 从可行位置集合 $P$  中选取距离 $\mathbf{s}'_m$ 最近的位置作为 $\mathbf{p}_{an}^m$ 。

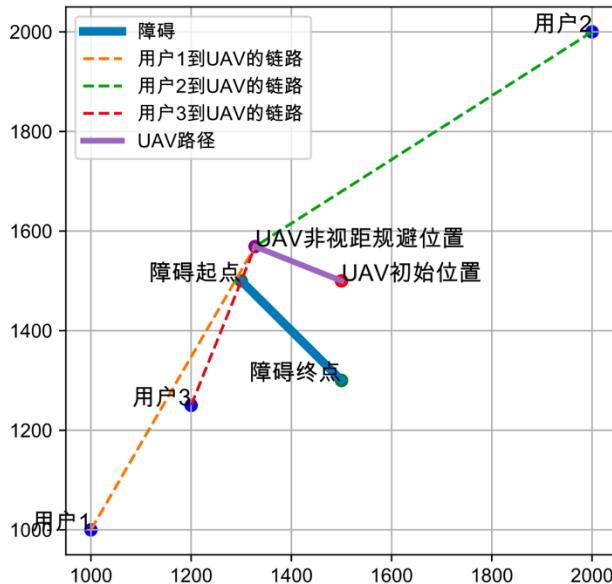


图 3-3 非视距规避位置效果图

不同于虚拟通信引力是无人机基站与用户两个节点之间的作用力, 由于使用三架及以上的无人机才能实现对地面节点的定位, 定位虚拟引力相应的是一组无人机与待定位节点之间的作用力, 该力的设计主要对应于优化目标中的定位误差优化与相应的定位约束条件。文献[20]中展示了, 对于采用 TDOA 的三个定位锚节点的情况, 待定位节点定位误差的克拉美罗界 (Cramer-Rao Lower Bound, CRLB) 随着向锚节点质心位置的趋近而降低。因此, 本研究面向 TDOA 的定位方式, 使定位引力的大小与待定位节点到质心的距离成反比, 并将用户 $u$ 对第 $k$ 个定位无人机子组 $C_k$ 中的 $k_i$ 无人机的虚拟定位引力表征如下:

$$\overrightarrow{\mathbf{F}_{al}^{u,k_l}} = \frac{K_a^L \times \max(\varepsilon_u^{th} - \varepsilon_{k,m}, 0)}{\|\hat{\mathbf{u}}_u' - \mathbf{c}_k\|^2} \quad (3-16)$$

其中  $\varepsilon_{k,m}$  为第  $k$  个定位无人机子组对第  $m$  个用户的克拉美罗界，  $\varepsilon_u^{th}$  为用户  $u$  期望的定位克拉美罗界，  $K_a^L$  为定位引力系数，第  $k$  个定位无人机子组  $\mathbf{c}_k$  在二维平面的质心位置为

$$\mathbf{c}_k = \frac{1}{|\mathbf{C}_k|} \sum_{i \in \mathbf{C}_k} \mathbf{s}'_{k,i}.$$

在虚拟引力的作用下，所有无人机基站将向着用户聚集，用户分布密集的区域可能会分布大量基站，基站之间的间距可能会非常小甚至相撞，同时产生冗余覆盖，在同一区域形成基站聚集的现象。因此，需要设计基站间的排斥力，该斥力能够使基站之间保持合适的间距，也能防止无人机在飞行部署过程中发生碰撞，该斥力的设计主要对应于无人机之间的防碰撞约束。为了确保基站不会过度聚集在一个区域带来碰撞等安全性问题，设置基站间的最小相对距离为阈值  $d_r^{th}$ ，设置的间距阈值不能超过基站之间的通信距离。如果两个相邻的可运动基站  $m$ 、 $n$  间的距离小于阈值  $d_r^{th}$ ，基站  $m$  将与该邻居基站  $n$  产生虚拟斥力  $\overrightarrow{F_r^{m,n}}$ ，斥力  $\overrightarrow{F_r^{m,n}}$  的计算公式如下：

$$\overrightarrow{F_r^{m,n}} = \overrightarrow{K_r \times \min(d_r^{th} - \|\mathbf{s}'_n - \mathbf{s}'_m\|, 0)}, \quad (3-17)$$

其中， $K_r$  为斥力系数，防碰撞的优先级高于其他一切覆盖、连通等需求，因此  $K_r$  大于其他所有系数，当基站间距离小于间距阈值  $d_r^{th}$  时，斥力将使运动基站会相互远离。在该虚拟斥力的作用下，基站会顺着二者连线并向着远离的方向移动。如果两个基站间的水平相对距离超过阈值距离  $d_r^{th}$ ，则不会产生影响二者移动的虚拟斥力。

当部署区域存在障碍（树林、山峰等），应急基站需要与障碍保持安全距离。在基站  $m$  的移动过程中，如果与障碍物  $\mathbf{o}_i$  的相对距离小于预先设置的安全距离  $d_o^{th}$ ，基站  $m$  将会受到斥力  $\overrightarrow{F_o^{m,i}}$  作用，该斥力的设计主要对应于无人机的避撞约束，具体如下：

$$\overrightarrow{F_o^{m,i}} = \overrightarrow{K_r \times \min(d_o^{th} - \|\mathbf{s}'_m - \mathbf{o}_i\|, 0)}, \quad (3-18)$$

其中， $\overrightarrow{F_o^{m,i}}$  障碍斥力方向由障碍物  $\mathbf{o}_i$  指向作用的基站  $m$ ， $\mathbf{o}_i$  表示障碍物  $i \in \mathcal{O} = \{1, 2, \dots, |\mathcal{O}|\}$  (待改为  $i$ ，下同) 的位置，其他参数意义同基站间斥力  $\overrightarrow{F_r}$  一致。

无人机基站  $m$  的虚拟合力将由以上五种虚拟力共同影响决定，即：

$$\overrightarrow{\mathbf{F}^m} = \sum_{u \in \mathcal{U}} \overrightarrow{\alpha_{u,m} \times \mathbf{F}_{ac}^{u,m}} + \sum_{u \in \mathcal{U}} \overrightarrow{\beta_{u,m} \times \mathbf{F}_{al}^{u,k_l}} + \sum_{n \in \mathcal{M}, n \neq m} \overrightarrow{\mathbf{F}_r^{n,m}} + \overrightarrow{\mathbf{F}_{an}^m} + \sum_{i \in \mathcal{O}} \overrightarrow{\mathbf{F}_o^{m,i}}. \quad (3-19)$$

其中，对于初始时刻  $t=1$  的无人机与用户的通信匹配关系  $\{\alpha_{u,m}(t=1)\}$ ，定义  $\text{idx}$  为无人机到用户  $u$  的信噪比集合  $\{\gamma_{1,u}(t), \dots, \gamma_{|\mathcal{M}|,u}(t)\}$  中最大值元素的序号，当  $\gamma_{\text{idx},u}(t) \geq \gamma_u^{th}$  时， $\alpha_{\text{idx},u}(t)=1, \forall u \in \mathcal{U}$ ；对于因为非视距遮挡导致没有无人机到用户  $u$  的信噪比高于  $\gamma_u^{th}$  的情况，将选取距离用户  $u$  最近的无人机对其提供服务并进行非视距规避。对于之后时刻  $t > 1$  的无人机与通信用户匹配关系  $\{\alpha_{u,m}(t)\}$ ，首先检查上一时刻的匹配  $\{\alpha_{u,m}(t-1)\}$  关系中所有用户  $u \in \mathcal{U}$  与所匹配的无人机之间信噪比是否仍大于信噪比阈值  $\gamma_u^{th}$ ，对于满足的用户，则保留原有的匹配关系；对于不满足的用户，则重新匹配所连接的无人机，即从信噪比集合  $\{\gamma_{1,u}(t), \dots, \gamma_{|\mathcal{M}|,u}(t)\}$  中选取最大值元素的序号  $\text{idx}$ ，如果  $\gamma_{\text{idx},u}(t) \geq \gamma_u^{th}$ ，则  $\alpha_{\text{idx},u}(t)=1$ ；对于因为非视距遮挡导致没有无人机到用户  $u$  的信噪比高于  $\gamma_u^{th}$  的情况，仍选取上一时刻正在对该用户进行非视距规避的无人机为其提供服务。

对于无人机与用户的定位匹配关系  $\{\beta_{u,m}(t)\}$ ，给定用户  $u \in \mathcal{U}$ ，根据其所有未被障碍物遮挡阻隔的无人机构建定位子组的集合  $\mathcal{K}_u = \{C_{u,1}, \dots, C_{u,k}, \dots, C_{u,K_u}\}$ ，从中选取在用户位置定位误差的 CRLB 最小的子组  $C_{u,best}$  为用户  $u$  提供定位服务，并将相应子组中的无人机与用户  $u$  的匹配关系置 1，即  $\beta_{m,u}(t)=1, \forall m \in C_{u,best}$ 。

进一步，将牛顿第二定律与虚拟力模型结合使用，以建模基站虚拟势力作用下的移动，即将移动距离表征为：

$$\overrightarrow{\Delta v_m} = \overrightarrow{F_m} \cdot \frac{\Delta t}{mass} = \overrightarrow{F_m} \cdot \Delta t, \quad (3-20)$$

其中  $mass$  为质量常数，这里假定为 1。定义无人机基站  $m$  在单位时间内的最大移动距离为  $d_m^{\max}$ ，本研究使用  $\arctan(\bullet)$  将速度范围归一化。为了保障网络整体的稳定服务时间，避免某些无人机节点提前耗尽能量导致整体网络不稳定，本研究在移动过程中加入剩余能量的考虑，具体建模如下：

$$\Delta \overrightarrow{v^m} = \arctan \left| \overrightarrow{F^m} \right| \times \frac{2}{\pi} \times d_m^{\max} \times \frac{\overrightarrow{F^m}}{\left| \overrightarrow{F^m} \right|} \times \frac{E_m^{\text{rest}}}{E_m^{\text{total}}}. \quad (3-21)$$

该移动步长的设计主要对应于优化目标中的无人机剩余能耗优化。因此，给定  $t-1$  时刻无人机  $m$  的坐标  $s_m^{t-1}$ ，无人机  $m$  在  $t$  时刻更新后的位置为：

$$\mathbf{s}_m^t = \mathbf{s}_m^{t-1} + \Delta \vec{v}^m. \quad (3-22)$$

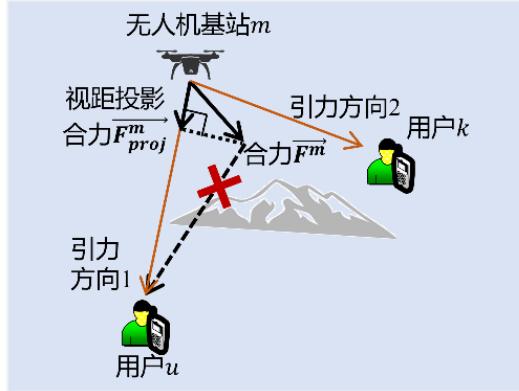


图 3-4 面向非视距规避的合力投影示意图

需要注意的是，非视距规避引力在无人机到达非视距规避位置之后将会置零。此时，非视距规避引力之外的合力占据主导地位可能会使基站再次回到非视距区域。具体而言，如图 3-4 所示，对于障碍物两侧都存在无人机基站要服务的用户的情况，无人机所受的通信引力等力的合力可能会指向非视距区域，使得无人机再次回到非视距区域，进而在视距和非视距的交界处循环往复。针对上述情况，本研究进一步设计了非视距规避投影合力，通过将无人机所受合力向视距方向投影来避免无人机再次进入非视距区域。假定无人机基站  $m$  位于  $\mathbf{s}_m^t$ ，即将变为非视距链路的用户  $u$  位于  $\mathbf{u}_u^t$ ，无人机当前所受合力为  $\overline{\mathbf{F}}^m$ ，则无人机基站  $m$  的视距投影合力  $\overline{\mathbf{F}}_{proj}^m$  可以通过如下公式计算：

$$\overline{\mathbf{F}}_{proj}^m = \frac{\overline{\mathbf{F}}^m \cdot \overline{\mathbf{u}_u^t - \mathbf{s}_m^t}}{\|\overline{\mathbf{u}_u^t - \mathbf{s}_m^t}\|^2} \overline{\mathbf{u}_u^t - \mathbf{s}_m^t}. \quad (3-23)$$

在完成投影之后，进一步非视距规避投影合力赋值到合力  $\overline{\mathbf{F}}^m$ ，即  $\overline{\mathbf{F}}^m = \overline{\mathbf{F}}_{proj}^m$ ，然后调用公式(4-23)和公式(4-24)对无人机的移动位置进行计算。

对于卫星定位服务可用的场景，应急用户不再需要无人机网络提供定位功能，可以通过将虚拟定位引力大小设置为 0，进而支撑面向通信需求的低复杂度高能效动态应急网络适配。

在根据用户位置变化动态适配基站位置的基础上，虚拟力算法也可以用于求解满足地面用户通导需求的最小基站数量。具体而言，通过虚拟力算法来指导基站的初始部署问题可分为如下两个阶段：基于地面用户位置和预设初始无人机数量  $N_{init}$ ，随机放置  $N_{min} = N_{init}$  个无人机作为初始状态；根据虚拟力算法进行位置更新迭代，对  $N_{min}$  架无人机根据用户分布及邻近基站状态计算虚拟力并实时更新位置。如果该初始部署经

过 $\delta_{\max}$ 次位置更新迭代后仍不能满足应急网络覆盖需求，证明 $N_{\min}$ 架无人机无法满足覆盖需求，因此增加无人机数量为 $N_{\min} = N_{\min} + 1$ ，并重复上述操作，直至无人机和地面基站可以覆盖所有用户，此时得到所需部署无人机的最小数量以及无人机的部署位置。

### 3.5 仿真结果与性能分析

#### 3.5.1 仿真设置

仿真基于 Python3.7 平台进行。仿真中的主要参数设计如下表所示，其中用户分布和无人机的部署范围为  $3\text{km} \times 3\text{km}$  大小区域。

表格 3-1 仿真参数表

参数	符号	数值
用户区域		$[-1500\text{m}, 1500\text{m}] \times [-1500\text{m}, 1500\text{m}]$
障碍物位置		$[-1030\text{m}, -400\text{m}] \times [-470\text{m}, -450\text{m}]$
载波频率	$f$	1.4GHz
无人机发射功率	$p$	26dBm
FSPL 参考距离	$d_0$	1m
无人机飞行高度	$h$	200m
SNR 阈值	$\gamma_u^{th}$	5 dB
林区倾斜信道参数	$A, C, E, G, H$	0.25、0.39、0.25、0、0.05
路径损耗因子	$\alpha$	3.5
阴影衰落标准差	$\sigma$	6
通信、定位引力因子	$K_a^C, K_a^L$	$1 \times 10^4$
非视距规避引力因子	$K_a^N$	$1 \times 10^6$
斥力因子	$K_r$	1000

### 3.5.2 存在非视距遮挡的通导耦合场景仿真结果分析

在卫星拒止的复杂场景下，应急无人机网络需要能为地面用户同时提供通信与定位服务，同时尽量规避非视距链路并保障应急网络的长效覆盖。本研究将所提出的高能效通导耦合（Energy-Efficient Integrated Communication-Localization, EF-ICL）虚拟力算法与以下两种方案在通导能效、算法执行时间、通信性能、定位性能与能耗方面进行了对比：

- Max-RL 算法[10]：该算法以最大化剩余网络能耗为优化目标，在通信与定位性能的约束下，基于遗传算法对网络部署位置进行动态调整。
- NEF-ICL (No Energy-Efficient Integrated Communication-Localization, NEF-ICL) 虚拟力算法：为了展示EF-ICL算法从不同层面带来的提升，本研究将未进行飞行能耗优化的通导耦合算法虚拟力作为对比方案之一。尽管参考文献[23]设计了面向通信覆盖增强的虚拟力部署方案，但该方案中缺少非视距规避以及信道模型设配，同时未考虑定位需求与能耗优化。为了保障性能对比的公平性，本研究设计了NEF-ICL虚拟力算法作为对比方案，该算法融入了定位虚拟力与非视距规避虚拟力等设计。

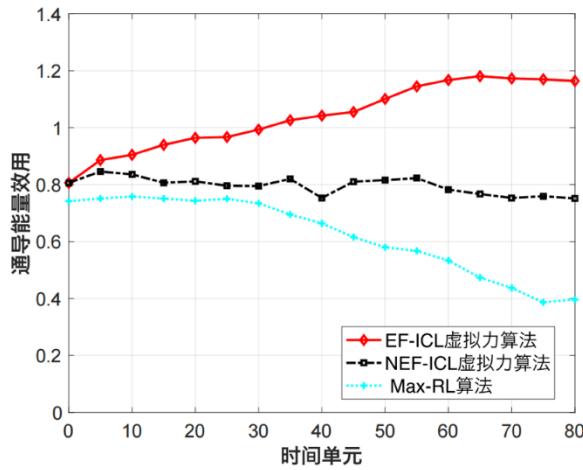


图 3-5 不同方案的通导能量效用对比

图 3-5 展示了在用户移动的过程中基于 EF-ICL 虚拟力算法、NEF-ICL 虚拟力算法以及 Max-RL 算法的应急无人机网络适配方案的通导能量效用变化。该通导能量效用的含义为，无人机每消耗百分之一的能量所带来的通信性能和定位性能加权和，其中通信性能（即传输速率）和定位性能（即 CRLB 迹的均值）分别进行了归一化处理以消除量纲。在图中，红色线条描绘了本研究提出的 EF-ICL 虚拟力算法在用户移动过程中的通导能量效用变化，蓝色线条则表现了 Max-RL 算法的相应变化，而黑色线条则代表了 NEF-ICL 虚拟力算法的通导能量效用变化。从图 3-5 中可以明显观察到，相较于

其他两种算法，本研究提出的 EF-ICL 虚拟力算法能够实现最高的通导能量效用。这主要得益于两个方面的因素。首先，本研究提出的高能效设计策略能够有效提高基于无人机基站的应急网络的工作时间。其次，相较于基于遗传算法的动态网络调整方案，EF-ICL 虚拟力算法在求解过程中保持了空间连续性，因此在飞行过程中基站移动距离较短，相应的移动能耗也较小。上述特性使得 EF-ICL 虚拟力算法在通导能量效用和无人机可用剩余能量上具有明显优势。

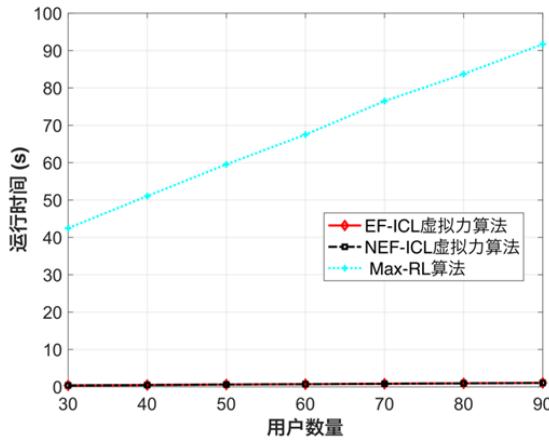


图 3-6 不同用户数量下算法的运行时间对比

图 3-6 展示了不同应急用户数量下 EF-ICL 虚拟力算法、NEF-ICL 虚拟力算法和 Max-RL 算法的运行时间对比。图中红色线条为所提 EF-ICL 虚拟力算法单次运行时间随用户数量的变化，黑色线条为 NEF-ICL 虚拟力算法相应的性能变化，蓝色线条为 Max-RL 算法单次运行时间随用户数量的变化。从图 3-6 中可以观察到，所提 EF-ICL 虚拟力算法相对于基于遗传算法的 Max-RL 算法可以有效降低算法的执行时间，将执行时间从分钟级缩短到了秒级。由于遗传算法为中心式的执行算法，在求解过程中需要进行大量的随机基因生成、全局信息的整体交换以及多次迭代的交叉变异，由此产生了大量的计算开销。而虚拟力算法在求解过程中重点针对作用力范围内的节点进行信息交换，并结合通导需求与非视距规避需求向合力的方向进行位置调整，因此相应的算法复杂度明显降低，使得算法执行时间更快。

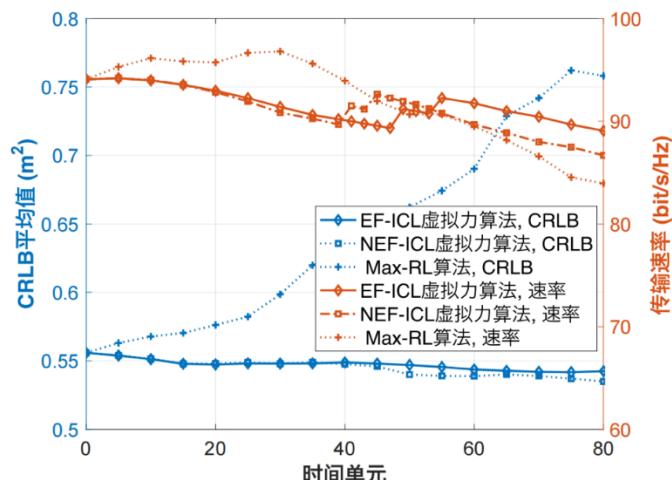


图 3-7 不同方案的通信与定位性能对比

图 3-7 对应急用户位置动态变化过程中，基于 EF-ICL 虚拟力算法、Max-RL 算法以及 NEF-ICL 虚拟力算法的应急无人机网络适配方案通信与定位性能进行了对比。其中在应急区域中，地面用户的数量为 42，并存在一个长 630 米宽 20 米的障碍物遮挡，使得 2 个用户在初始时刻无法被无人机视距覆盖。图中棕色线条表示用户可达传输速率随着用户移动的变化，蓝色线条表示用户定位的 CRLB 平均值随着用户移动的变化。从图 3-7 中可以观察到，在第 48 个时间单元 EF-ICL 虚拟力算法的传输速率有一个阶梯形的提升，对应无人机完成了第一个用户的非视距规避；在第 54 个时间单元 EF-ICL 虚拟力算法的传输速率第二个阶梯形的提升，对应无人机完成了第二个用户的非视距规避；同时，可以注意到，NEF-ICL 虚拟力算法的传输速率阶梯形提升要早于 EF-ICL 虚拟力算法，这是因为 EF-ICL 虚拟力算法的能耗优化会使无人机的移动速度有一定程度的下降。总体而言，相较于 NEF-ICL 虚拟力算法，EF-ICL 虚拟力算法在通信速度上取得了相当的性能，并在部分时刻下取得了更高的传输速率。对于定位性能而言，在前 40 个时间单元中，EF-ICL 虚拟力算法的定位性能与 NEF-ICL 虚拟力算法的性能相当。在第 40 个时间单元之后，EF-ICL 虚拟力算法的性能略微差于 NEF-ICL 虚拟力算法。此外，相较于 Max-RL 算法，EF-ICL 虚拟力算法在定位性能上取得了明显的优势。这是因为基于遗传算法的动态位置适配缺乏空间连续性上的深度优化，需要大量的随机种子以探寻更优的解，更依赖于随机生成的基因和交叉变异的概率性事件，当未生成性能足够优秀的基因时，容易导致通信与定位性能的逐渐下降。

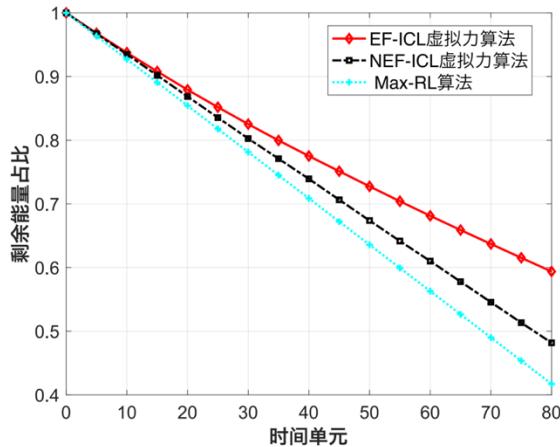


图 3-8 移动过程不同方案的剩余能量占比对比

图 3-8 展示了在应急用户位置动态变化过程中基于 EF-ICL 虚拟力算法、Max-RL 算法以及 NEF-ICL 虚拟力算法的应急无人机网络适配方案的剩余能量变化对比。在图中，红色线条描绘了本研究提出的 EF-ICL 虚拟力算法在用户移动过程中的剩余能量占比变化，蓝色线条则表现了 Max-RL 算法的相应变化，而黑色线条则代表了 NEF-ICL 虚拟力算法的剩余能量占比变化。从图 3-8 中可以观察到，相较于其他两种算法，EF-ICL 虚拟力算法能够实现最多的剩余能量。当剩余能量占比为 60% 时，EF-ICL 虚拟力算法的工作时间相对于 NEF-ICL 虚拟力算法提升超过 27%，相对于 Max-RL 提升超过 43%。

这主要得益于两个方面的因素。首先，本研究提出的高能效设计策略能够有效提高基于无人机基站的应急网络的工作时间。其次，相较于基于遗传算法的动态网络调整方案，EF-ICL 虚拟力算法在求解过程中保持了空间连续性，因此在飞行过程中基站移动距离较短，相应的移动能耗也较小。这一特性使得该算法在网络可用剩余能量上具有明显优势。

### 3.5.3 无非视距遮挡的通导耦合场景仿真结果分析

为了更全面地展示各通导耦合应急网络部署方案的性能，本研究进一步对比了不存在山体类严重遮挡情况下的 EF-ICL 虚拟力算法、Max-RL 算法和 NEF-ICL 虚拟力算法在通导能效、算法执行时间、通信性能、定位性能与能耗方面的性能。

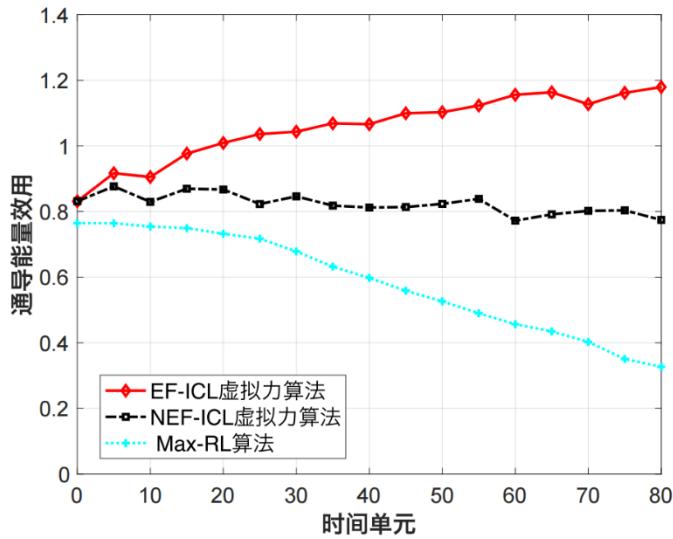


图 3-9 移动过程不同方案的通导能量效用对比

图 3-9 展示了在用户移动的过程中基于 EF-ICL 虚拟力算法、NEF-ICL 虚拟力算法以及 Max-RL 算法的应急无人机网络适配方案的通导能量效用变化。在图中，红色线条描绘了本研究提出的 EF-ICL 虚拟力算法在用户移动过程中的通导能量效用变化，蓝色线条则表现了 Max-RL 算法的相应变化，而黑色线条则代表了 NEF-ICL 虚拟力算法的通导能量效用变化。从图 3-9 中可以观察到，相较于其他两种算法，所提出的 EF-ICL 虚拟力算法能够实现最高的通导能量效用。同时 NEF-ICL 虚拟力算法能够获得高于 Max-RL 算法的通导能量效用。

图 3-10 展示了不同应急用户数量下 EF-ICL 虚拟力算法、NEF-ICL 虚拟力算法和 Max-RL 算法的运行时间对比。图中红色线条为所提 EF-ICL 虚拟力算法单次运行时间随用户数量的变化，黑色线条为 NEF-ICL 虚拟力算法相应的性能变化，蓝色线条为 Max-RL 算法单次运行时间随用户数量的变化。从图 3-10 中可以观察到，所提 EF-ICL 虚拟力算法相对于基于遗传算法的 Max-RL 算法可以有效降低算法的执行时间，将执行时间从分钟级缩短到了秒级。

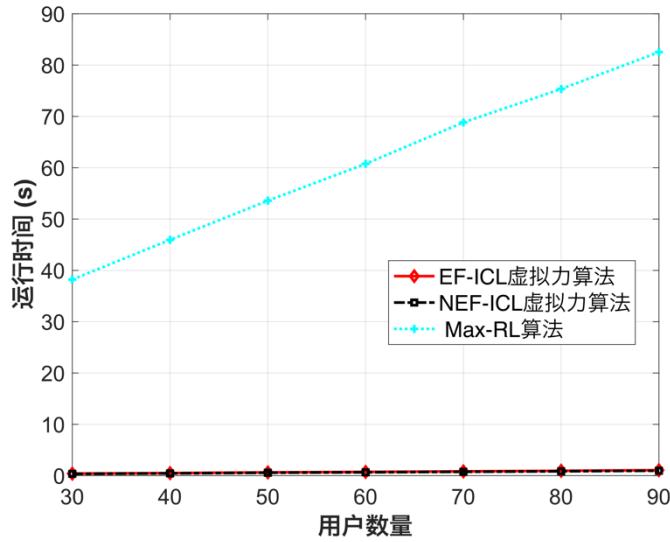


图 3-10 不同用户数量下算法的运行时间对比

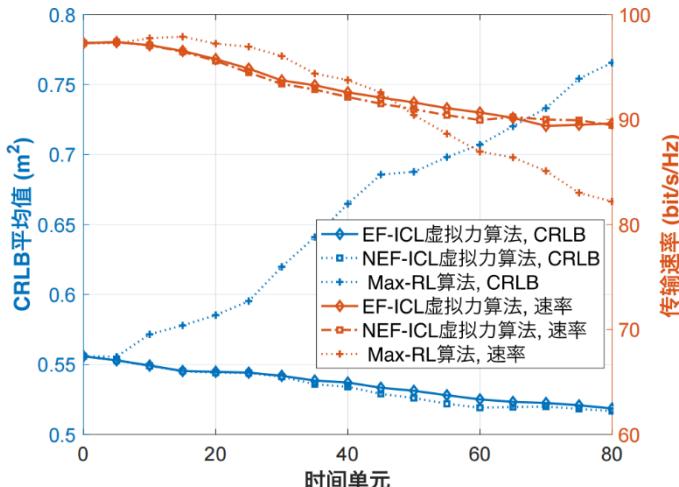


图 3-11 不同方案的通信与定位性能对比

图 3-11 对应急用户位置动态变化过程中，基于 EF-ICL 虚拟力算法、Max-RL 算法以及 NEF-ICL 虚拟力算法的应急无人机网络适配方案通信性能进行了对比。图中棕色线条表示用户可达传输速率随着用户移动的变化，蓝色线条表示用户定位的 CRLB 平均值随着用户移动的变化。从图 3-11 中可以观察到，不同于存在非视距链路需要规避的场景，EF-ICL 虚拟力算法和 NEF-ICL 虚拟力算法的传输速率不再存在阶梯形的变化。总体而言，相较于 NEF-ICL 虚拟力算法，EF-ICL 虚拟力算法在通信速度上取得了相当的性能，而 Max-RL 则存在通信速率逐渐下降的情况。此外，在前 30 个时间单元中，EF-ICL 虚拟力算法的定位性能与 NEF-ICL 虚拟力算法的性能相当。在第 30 个时间单元之后，EF-ICL 虚拟力算法的性能略微差于 NEF-ICL 虚拟力算法。这是因为 EF-ICL 虚拟力算法为了确保应急网络的持久覆盖，以牺牲一部分定位性能为代价，以获取更长的网络服务时间。因此，随着剩余能耗的降低，无人机网络的定位性能出现了轻微下降。同时，与存在非视距遮挡的场景相比，EF-ICL 虚拟力算法在无非视距遮挡的场

景下可以取得更低的定位误差。此外，相较于 Max-RL 算法，EF-ICL 虚拟力算法在定位性能上取得了明显的优势。

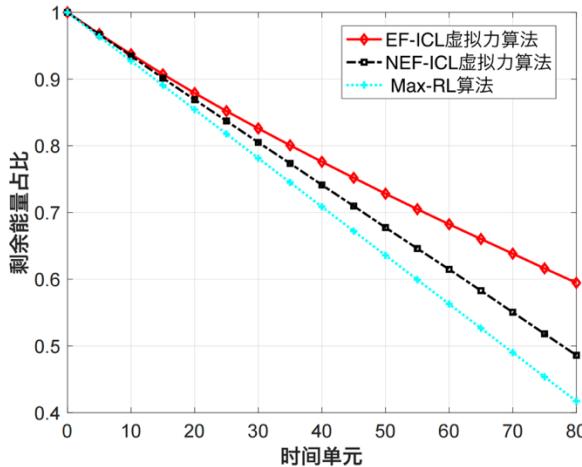


图 3-12 移动过程不同方案的剩余能量占比对比

图 3-12 展示了在应急用户位置动态变化过程中基于 EF-ICL 虚拟力算法、Max-RL 算法以及 NEF-ICL 虚拟力算法的应急无人机网络适配方案的剩余能量变化对比。在图中，红色线条描绘了本研究提出的 EF-ICL 虚拟力算法在用户移动过程中的剩余能量占比变化，蓝色线条则表现了 Max-RL 算法的相应变化，而黑色线条则代表了 NEF-ICL 虚拟力算法的剩余能量占比变化。从图 3-12 中可以观察到，相较于其他两种算法，EF-ICL 虚拟力算法能够实现最多的剩余能量。当剩余能量占比为 60% 时，EF-ICL 虚拟力算法的工作时间相对于 NEF-ICL 虚拟力算法提升超过 25%，相对于 Max-RL 提升超过 43%。

### 3.5.4 存在非视距遮挡的通信保障场景仿真结果分析

当卫星定位服务可用时，应急无人机网络需要在为地面用户提供通信服务的同时，应尽量规避非视距链路并保障应急通信网络的长效覆盖。因此，本节面向应急通信覆盖需求对以下三种方案进行性能对比：

- EF (Energy-Efficient) 虚拟力算法：与所设计的EF-ICL虚拟力算法相比，EF 虚拟力算法移除了定位虚拟力，重点保留通信虚拟力、非视距规避虚拟和能效优化设计。
- Max-RL算法[10]：该算法以最大化剩余网络能耗为优化目标，在通信与定位性能的约束下，基于遗传算法对网络部署位置进行动态调整。在本节中去掉了算法中的定位性能约束。
- NEF (No Energy-Efficient) 虚拟力算法：与所设计的NEF-ICL虚拟力算法相比，NEF虚拟力算法移除了定位虚拟力，重点保留通信虚拟力、非视距规避虚拟

和能效优化设计。尽管参考文献[23]设计了面向通信覆盖增强的虚拟力部署方案，但该方案中缺少非视距规避以及信道模型设配，同时未考虑能耗优化。为了保障性能对比的公平性，本研究设计了NEF虚拟力算法作为对比方案，该算法融入了非视距规避虚拟力等设计。

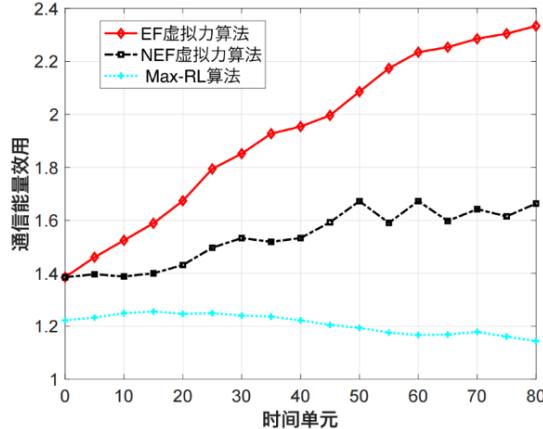


图 3-13 移动过程不同方案的通导能量效用对比

图 3-13 展示了在用户移动的过程中基于 EF 虚拟力算法、NEF 虚拟力算法以及 Max-RL 算法的应急无人机网络适配方案的通信能量效用变化。通信能量效用的含义为，无人机每消耗百分之一的能量所提供的通信性能，其中通信性能（即传输速率）使用三种方案所能达到的最大传输速率进行了归一化处理以消除量纲。在图中，红色线条描绘了本研究提出的 EF 虚拟力算法在用户移动过程中的通导能量效用变化，蓝色线条则表现了 Max-RL 算法的相应变化，而黑色线条则代表了 NEF 虚拟力算法的通信能量效用变化。从图 3-13 中可以观察到，相较于其他两种算法，本研究提出的 EF-ICL 虚拟力算法能够实现最高的通导能量效用，说明 EF 虚拟力算法在通导能量效用和无人机可用剩余能量上具有明显优势。

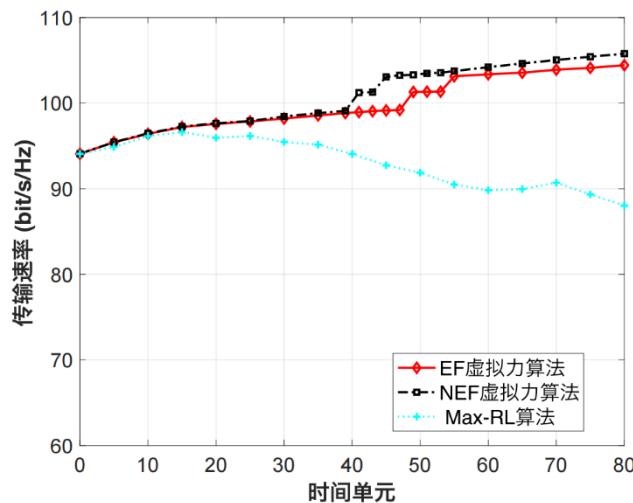


图 3-14 不同方案的通信性能对比

图 3-14 对应急用户位置动态变化过程中，基于 EF 虚拟力算法、Max-RL 算法以及 NEF 虚拟力算法的应急无人机网络适配方案通信性能进行了对比。其中在应急区域中，

地面用户的数量为 42，并存在一个长 630 米宽 20 米的障碍物遮挡，使得 2 个用户在初始时刻无法被无人机视距覆盖。图中红色线条描绘了本研究提出的 EF 虚拟力算法的用户可达传输速率如何随着用户移动而变化，蓝色线条则展示了 Max-RL 算法的相关变化，而黑色线条代表了 NEF 虚拟力算法的性能变化。从图 3-14 中可以观察到，EF-ICL 虚拟力算法的传输速率在第 46 到第 56 个时间单元内有两个阶梯形的提升，对应无人机完成了两个用户的非视距规避；同时，可以注意到，NEF-ICL 虚拟力算法的传输速率阶梯形提升要早于 EF-ICL 虚拟力算法。不同于通导耦合场景，相较于 EF-ICL 算法，NEF-ICL 虚拟力算法在第 25 个时间单元后均可以取得更高的传输速率，说明当不存在定位虚拟力影响合力之后，NEF-ICL 虚拟力通过使用更高的能耗获取了更大的通信速率。此外，相较于基于遗传算法的 Max-RL 算法，EF 虚拟力算法在通信性能上展现了有效的提升。

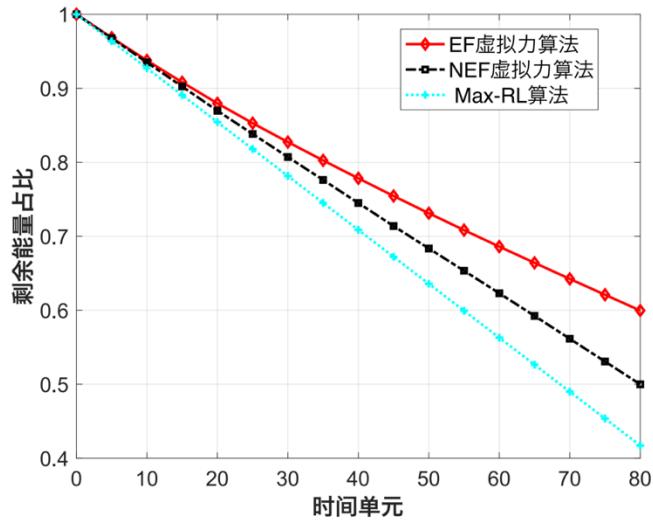


图 3-15 不同方案随时间推移的剩余能量变化对比

图 3-15 展示了在应急用户位置动态变化过程中基于 EF 虚拟力算法、Max-RL 算法以及 NEF 虚拟力算法的应急无人机网络适配方案的剩余能量变化对比。在图中，红色线条描绘了本研究提出的 EF 虚拟力算法在用户移动过程中的剩余能量占比变化，蓝色线条则表现了 Max-RL 算法的相应变化，而黑色线条则代表了 NEF 虚拟力算法的剩余能量占比变化。从图 3-15 中可以观察到，相较于其他两种算法，EF-ICL 虚拟力算法在相同的服务时间下能够实现最多的剩余能量。潜在的原因如下：首先，本研究提出的高能效设计策略能够有效提高基于无人机基站的应急网络的工作时间。其次，相较于基于遗传算法的动态网络调整方案，EF 虚拟力算法在求解过程中更好的保持了空间连续性，因此在飞行过程中基站移动距离较短，相应的移动能耗也较小。这一特性使得该算法在网络服务时间上具有明显优势。

### 3.6 小结

本研究针对灾害现场人员移动引发的通信性能与定位精度下降，结合虚拟力模型设计了高能效动态应急网络部署位置更新方案。具体而言，本研究面向应急通导需求建立了用户对基站的虚拟通信引力、用户对基站的虚拟定位引力、非视距规避点对于基站的引力、基站之间避免碰撞的虚拟斥力和基站与障碍物之间的虚拟斥力五种虚拟力模型，并结合无人机基站剩余能耗自适应调整无人机每次适配的移动距离，在保障应急网络服务质量的情况下有效提升整体网络的服务时间。仿真结果展示了相对于现有的动态网络适配方案，所提 EF-ICL 虚拟力算法在保障通信与定位服务性能的前提下可以快速实现更为长效的应急网络覆盖，更契合实际应急救援现场的网络调度需求。

## 参考文献

- [1] Mozaffari M, Saad W, Bennis M, et al. Efficient deployment of multiple unmanned aerial vehicles for optimal wireless coverage[J]. IEEE Communications Letters, 2016, 20(8): 1642-1650.
- [2] Alzena D M, El-Keyi A, Lagum F, et al. 3D placement of an unmanned aerial vehicle base station (UAV-BS) for energy-efficient maximal coverage[J]. IEEE Wireless Communications Letters, 2017, 6(99): 434-435.
- [3] Ahmed S, Chowdhury M Z, Jang Y M. Energy-efficient UAV relaying communications to serve ground nodes[J]. IEEE Communications Letters, 2020, 24(4): 849-852.
- [4] Do-Duy T, et al. Joint optimization of real-time deployment and resource allocation for UAV-aided disaster emergency communications[J]. IEEE Journal on Selected Areas in Communications, 2021, 39(11): 3411-3424.
- [5] Wang T, Liu Z, Xu L, Wang L. An efficient and robust UAVs' path planning approach for timely data collection in wireless sensor networks [C]//2022 IEEE Wireless Communications and Networking Conference (WCNC), 2022:914-919.
- [6] Wu X, Wang L, Xu L, Liu Z, Fei A. Joint optimization of UAVs 3-D placement and power allocation in emergency communications [C]//2021 IEEE Global Communications Conference (GLOBECOM), 2021:1-6.
- [7] Reina D, Tawfik H, Toral S. Multi-subpopulation evolutionary algorithms for coverage deployment of UAV-networks[J]. Ad Hoc Networks, 2018, 68: 16-32.
- [8] Liu G, Shakhatreh H, Khreichah A, Guo X, Ansari N. Efficient deployment of UAVs for maximum wireless coverage using genetic algorithm [C]//Proceedings of IEEE 39th Sarnoff Symposium, 2018:1-6.
- [9] Mozaffari M, Saad W, Bennis M, Debbah M. Efficient Deployment of Multiple Unmanned Aerial Vehicles for Optimal Wireless Coverage[J]. IEEE Communications Letters, 2016, 20(8): 1647-1650.
- [10] Yu X, Liu Z, Xu L, Wang L. Lifetime Maximization for UAV-Enabled Integrated Localization and Communication Networks in Emergency Scenarios[C]//2022 14th International Conference on Wireless Communications and Signal Processing (WCSP). Nanjing, China, 2022: 905-909.

- [11] Zeng Y, Zhang R, Lim T J. Wireless Communications with Unmanned Aerial Vehicles: Opportunities and Challenges[J]. IEEE Communications Magazine, 2016, 54(5): 36-42.
- [12] Wang L, Zhu H. Simple Engineering Algorithms of Transmission Loss in Short Range Troposcatter Communications across Mountains[J]. Radio Engineering, 2018, 48(6): 512-515.
- [13] Dai Z, Wang G, Jin X, Lou X. Nearly Optimal Sensor Selection for TDOA-Based Source Localization in Wireless Sensor Networks[J]. IEEE Transactions on Vehicular Technology, 2020, 69(10): 12031-12042.
- [14] McGuire M, Plataniotis KN. A comparison of radiolocation for mobile terminals by distance measurements[C]//Proc. Int. Conf. Wireless Commun. 2000, 2000: 1356-1.
- [15] Zeng Y, Xu J, Zhang R. Energy Minimization for Wireless Communication With Rotary-Wing UAV[J]. IEEE Transactions on Wireless Communications, 2019, 18(4): 2329-2345.
- [16] Shin S, Lee U, Dressler F, Yoon H. Analysis of Cell Sojourn Time in Heterogeneous Networks With Small Cells[J]. IEEE Communications Letters, 2016, 20(4): 788-791.
- [17] Wang H, et al. Deployment algorithms of flying base stations: 5G and beyond with UAVs[J]. IEEE Internet of Things Journal, 2019, 6(6): 10009-10027.
- [18] Apolinario J A, Yazdanpanah H, Nascimento A S, Campos M L R de. A Data-selective LS Solution to TDOA-based Source Localization[C]//2019 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). 2019: 4400-4404.
- [19] Zhou Y, Lamont L. Constrained linear least squares approach for TDOA localization: A global optimum solution[C]//2008 IEEE International Conference on Acoustics, Speech and Signal Processing. Las Vegas, NV, USA, 2008: 2577-2580.
- [20] McGuire M, Plataniotis KN. A comparison of radiolocation for mobile terminals by distance measurements[C]//Proc. Int. Conf. Wireless Commun. 2000, 2000: 1356-1.
- [21] Liu G, Shakhatreh H, Khreichah A, Guo X, Ansari N. Efficient Deployment of UAVs for Maximum Wireless Coverage Using Genetic Algorithm[C]//2018 IEEE 39th Sarnoff Symposium. Newark, NJ, USA, 2018: 1-6.
- [22] Bhattarai S, Wei S, Rook S, Yu W, Griffith D, Golmie N. Optimizing the location deployment of dynamic mobile base stations[C]//2015 International Conference on Computing, Networking and Communications (ICNC). Garden Grove, CA, USA, 2015: 579-583.

- [23] Zhao H, Wang H, Wu W, Wei J. Deployment Algorithms for UAV Airborne Networks Toward On-Demand Coverage[J]. IEEE Journal on Selected Areas in Communications, 2018, 36(9): 2015-2031.

## 4 总结

本研究针对高效应急救援与可靠组网需求，以实现应急现场救援业务的通信能力与定位精度高效保障为目标，研究智能应急通信与定位增强方法，从面向差异化环境小样本数据的鲁棒 CSI 反馈和面向移动应急场景的动态通导网络适配两个方面出发，保障可靠应急通信与定位网络覆盖，提升应急现场指挥的准确性与时效性，为灾后现场救援行动的开展提供可靠网络支撑与通导业务支持。具体如下：

### 1、面向差异化环境小样本数据的鲁棒 CSI 反馈

在人口较为密集的应急场景下，基站退服区域的受灾用户需要通过接入周边正常基站获取通信支撑，使得基站需要能够压缩原有用户的频谱占用，以容纳更多的通信用户。基于数据驱动的高维 CSI 低开销反馈可以用于提升有限带宽资源下基站的频谱利用率，然而由于应急现场信道测量成本高、时间长，亟需基于少量测量样本挖掘无线信道环境的特征，并根据用户位置变化及时适配 CSI 反馈模型，支持用户在有限的频谱资源下保持稳定的信道反馈精度。因此，本研究聚集鲁棒 CSI 反馈，基于 CSI 特征翻译和轻量化数据增强设计了面向差异化环境小样本数据的 CSI 反馈方案，保障在有限测量样本和动态信道环境下的高精度 CSI 反馈和高效频谱利用。具体地，首先设计了基于深度展开和球面归一化的 CSI 反馈锚网络，保障模型对在复杂信道环境下的反馈精度；在此基础上，提出了一种场景自适应 CSI 反馈架构，通过设计由稀疏对齐功能和轻量级 DL 模块组成的可插拔 CSI 翻译模块，支持在全新信道环境中的预训练模型高效复用，进而设计了一种基于领域知识的轻量级信道数据增强策略，在少量信道测量数据下提升信道反馈的精度，为城市等人口密集应急环境下信道反馈模型的低开销高精度部署优化提供解决方案。

### 2、面向移动应急场景的动态通导网络适配

在应急救援过程中常面临救援力量高度机动和地面人员位置动态变化等情况，使得静态部署方案难以目标用户提供稳定的网络覆盖，需要根据地面用户的即时位置和通导需求快速适配应急基站的部署位置。因此，本研究聚焦无人机辅助的动态应急网络调整，提出了基于虚拟力模型的应急通导网络动态适配方案，保障移动场景下应急网络的稳定覆盖。为了满足动态场景下基站位置调整的快速输出，本研究设计了基于通

信需求、定位需求和非视距规避需求的虚拟引力建模方案、以及基于无人机避撞需求的虚拟斥力建模方案，支撑基于基站所受合力的低复杂度应急网络部署位置调整。针对无人机能量受限带来的网络节点失能和拓扑变化问题，本研究进一步设计了无人机能量自适应的移动步长适配方案，在保障应急通导网络高效覆盖的前提下有效提升无人机节点的工作时间，并支持秒级的动态位置调整方案快速输出。